

**Analisis dan Perbandingan Efektivitas Fitur
Higher-Order Statistics, Wavelet, dan Power
Spectrum Density dalam Model Convolutional
Neural Network untuk Lokalisasi Premature
Ventricular Contraction**

Proposal Tugas Akhir

Kelas TA SMD

**Zafira Nur Kamila
NIM: 103012330195**



**Program Studi Sarjana Teknik Informatika
Fakultas Informatika
Universitas Telkom
Bandung
2026**

Lembar Persetujuan

Analisis dan Perbandingan Efektivitas Fitur Higher-Order Statistics, Wavelet, dan Power Spectrum Density dalam Model Convolutional Neural Network untuk Lokalisasi Premature Ventricular Contraction

Analysis and Comparison of the Effectiveness of Higher-Order Statistics, Wavelet, and Power Spectrum Density Features in a Convolutional Neural Network Model for Premature Ventricular Contraction Localization

Zafira Nur Kamila
NIM: 103012330195

Proposal ini diajukan sebagai usulan pembuatan tugas akhir pada
Program Studi Sarjana Teknik Informatika
Fakultas Informatika Universitas Telkom

Bandung, 25 Mei 2026
Menyetujui

Calon Pembimbing

Satria Mandala, PhD
NIP: 16730040

Abstrak

Premature Ventricular Contraction (PVC) merupakan salah satu jenis aritmia jantung yang ditandai dengan munculnya kontraksi ventrikel lebih awal dari ritme jantung normal. Lokalisasi sumber PVC secara akurat menjadi hal penting karena dapat membantu proses analisis klinis secara non-invasif serta mendukung perencanaan tindakan medis seperti ablasi kateter. Sinyal Electrocardiogram (ECG) 12-lead memiliki informasi penting untuk mengenali karakteristik PVC, namun sinyal ECG bersifat kompleks, non-stasioner, dan dapat mengandung pola non-linear. Oleh karena itu, diperlukan metode ekstraksi fitur yang mampu merepresentasikan karakteristik sinyal ECG secara lebih informatif. Penelitian ini mengusulkan analisis dan perbandingan efektivitas tiga metode ekstraksi fitur, yaitu Higher-Order Statistics (HOS), Wavelet Transform, dan Power Spectrum Density (PSD), dalam model Convolutional Neural Network (CNN) untuk lokalisasi PVC. Data yang digunakan merupakan dataset publik ECG 12-lead yang memiliki label lokasi asal PVC. Pada penelitian ini, lokalisasi PVC dibatasi pada klasifikasi lokasi asal PVC ke dalam dua kelas utama, yaitu Right Ventricular Outflow Tract (RVOT) dan Left Ventricular Outflow Tract (LVOT), sehingga penelitian tidak berfokus pada lokalisasi sublokasi anatomis secara lebih rinci. Tahapan penelitian meliputi pengumpulan data, preprocessing, ekstraksi fitur, pembangunan model CNN baseline, hyperparameter tuning, penanganan ketidakseimbangan data, evaluasi model, serta analisis kontribusi fitur menggunakan Explainable Artificial Intelligence (XAI). Pengujian dilakukan melalui beberapa skenario, yaitu penggunaan fitur individual PSD, Wavelet, dan HOS, serta kombinasi fitur melalui skema feature fusion. Performa model dievaluasi menggunakan metrik akurasi, presisi, recall, F1-score, AUC, macro-F1, balanced accuracy, confusion matrix, waktu pelatihan, waktu inferensi, dan penggunaan memori. Penelitian ini diharapkan dapat mengetahui metode ekstraksi fitur dan skema fusi fitur yang paling efektif dalam meningkatkan performa klasifikasi lokasi asal PVC berbasis CNN pada kelas RVOT dan LVOT.

Kata Kunci: Premature Ventricular Contraction, ECG, Convolutional Neural Network, Higher-Order Statistics, Wavelet Transform, Power Spectrum Density, RVOT, LVOT

Daftar Isi

Lembar-Persetujuan	i
Abstrak	ii
Daftar Isi	iii
I Pendahuluan	1
1.1 Latar Belakang	1
1.2 Perumusan Masalah	2
1.3 Pernyataan Masalah	3
1.4 Tujuan	3
1.5 Batasan Masalah	3
1.6 Hipotesis	4
1.7 Sistematika Penulisan	4
II Kajian Pustaka	6
2.1 Penelitian Terkait	6
2.2 Elektrokardiogram (ECG) dan Fisiologi PVC	12
2.2.1 Konduksi Jantung Normal vs. Ektopik	12
2.2.2 Signifikansi Klinis Lokalisasi (<i>Site of Origin</i>)	12
2.3 Power Spectrum Density (PSD)	12
2.3.1 Definisi dan Statistik Orde Kedua	12
2.3.2 Estimasi Metode Welch	13
2.4 Wavelet Transform (WT)	13
2.4.1 Multiresolution Analysis (MRA)	13
2.4.2 Discrete Wavelet Transform (DWT)	13
2.5 Higher-Order Statistics (HOS)	14
2.5.1 Melampaui Linearitas dan Gaussianitas	14
2.5.2 Bispectrum dan Quadratic Phase Coupling (QPC)	14
2.6 Convolutional Neural Network (CNN)	14
2.6.1 Feature Learning vs. Hand-crafted Features	14
2.6.2 Arsitektur Multi-Branch untuk Fusi Fitur	14
2.7 Ringkasan	15

III Metodologi dan Desain Sistem	17
3.1 Metode Penelitian	17
3.1.1 Framework Penelitian	17
3.1.2 Metodologi untuk Mencapai Tujuan Penelitian	20
3.1.3 Analisis Kebutuhan Sistem	24
3.1.4 Definisi Lokalisasi PVC	25
3.1.5 Data	25
3.1.6 Posisi Fitur terhadap Model CNN	28
3.1.7 Formulasi Ekstraksi Fitur	30
3.1.8 Pembagian Data dan Validasi Model	33
3.1.9 Metrik Uji	34
3.1.10 Model Baseline	39
3.1.11 Hyperparameter Tuning Model CNN	42
3.1.12 Penanganan Ketidakseimbangan Data	43
3.1.13 Explainable Artificial Intelligence (XAI)	44
3.1.14 Metode Pengujian	46
3.1.15 Perbandingan Hasil Penelitian	49
3.2 Desain Sistem	50
3.3 Ringkasan	52
Daftar Pustaka	53
Lampiran A	55
Jadwal Kegiatan	55

Bab I

Pendahuluan

1.1 Latar Belakang

Premature Ventricular Contraction (PVC) merupakan salah satu bentuk aritmia jantung yang paling umum dijumpai dalam praktik klinis. PVC ditandai dengan kontraksi ventrikel yang terjadi lebih awal dari siklus jantung normal, menghasilkan pola elektrokardiogram (ECG) yang abnormal [1]. Meskipun PVC sering bersifat jinak pada individu sehat, kejadian PVC yang sering dan kompleks dapat menjadi indikator penting dari kondisi patologis yang mendasari seperti kardiomiopati, iskemia miokard, atau gangguan elektrolit [2]. Lebih lanjut, PVC yang berasal dari lokasi tertentu di ventrikel dapat memicu aritmia yang lebih berbahaya seperti takikardia ventrikel atau fibrilasi ventrikel, yang berpotensi mengancam jiwa [3].

Lokalisasi sumber PVC secara akurat memiliki implikasi klinis yang signifikan, terutama dalam perencanaan prosedur ablasi kateter untuk terapi kuratif. Ablasi kateter telah menjadi modalitas terapi yang efektif untuk PVC simptomatik atau PVC yang menyebabkan disfungsi ventrikel [4]. Keberhasilan prosedur ablasi sangat bergantung pada identifikasi lokasi asal PVC yang tepat sebelum dan selama prosedur. Metode konvensional untuk lokalisasi PVC mengandalkan analisis morfologi ECG 12-lead dan pemetaan elektrofisiologi invasif, yang memerlukan waktu, biaya tinggi, dan membawa risiko prosedural. Identifikasi lokasi asal yang presisi secara non-invasif dapat memperpendek waktu pemetaan dan meminimalkan risiko komplikasi [2, 5].

Dalam dekade terakhir, berbagai pendekatan komputasional telah dikembangkan untuk meningkatkan akurasi dan efisiensi lokalisasi PVC non-invasif menggunakan analisis sinyal ECG. Pendekatan-pendekatan ini umumnya melibatkan ekstraksi fitur dari sinyal ECG diikuti dengan algoritma klasifikasi. Namun, sinyal ECG memiliki karakteristik yang kompleks: bersifat non-linear dan non-stasioner [6, 7]. Karakteristik ini menimbulkan tantangan signifikan bagi metode analisis sinyal konvensional yang sebagian besar didasarkan pada asumsi linearitas dan stasioneritas [8].

Metode ekstraksi fitur tradisional seperti *Power Spectrum Density* (PSD) hanya memanfaatkan statistik orde dua dan buta terhadap informasi fase, se-

hingga tidak mampu menangkap karakteristik non-linear dan *coupling* fase yang penting dalam sinyal ECG abnormal [7]. Transformasi Wavelet telah menunjukkan kemampuan yang lebih baik dalam analisis sinyal non-stasioner melalui representasi waktu-frekuensi, namun masih memiliki keterbatasan dalam menangkap interaksi non-linear antar-komponen frekuensi [6]. *Higher-Order Statistics* (HOS) menawarkan kerangka kerja yang lebih komprehensif untuk analisis sinyal non-linear dan non-Gaussian karena mampu mengungkap *coupling* fase antar-komponen frekuensi [9].

Seiring perkembangan teknologi, *Convolutional Neural Network* (CNN) telah terbukti sangat efektif dalam mengekstraksi pola hierarkis dari sinyal kompleks secara otomatis [3, 10]. Namun, efektivitas model CNN dalam lokalisasi PVC sangat bergantung pada kualitas input fitur [11]. Penelitian ini mengusulkan penggunaan tiga pendekatan fitur (HOS, PSD, dan Wavelet) yang diintegrasikan ke dalam arsitektur CNN. Berbeda dengan penelitian sebelumnya yang cenderung mengisolasi metode, penelitian ini melakukan perbandingan sistematis terhadap performa fitur secara individual serta berbagai skema fusi fitur seperti kombinasi HOS dan PSD, HOS dan Wavelet, PSD dan Wavelet, maupun integrasi ketiga fitur tersebut sekaligus untuk menentukan konfigurasi yang paling optimal [4, 12].

Berdasarkan latar belakang tersebut, penelitian ini bertujuan untuk mengevaluasi dan mengoptimalkan performa ekstraksi fitur berbasis HOS, Wavelet Transform, dan Power Spectrum Density pada Convolutional Neural Network untuk lokalisasi Premature Ventricular Contraction pada kelas RVOT dan LVOT yang presisi pada sinyal ECG, serta membandingkan kinerjanya melalui skema fusi fitur yang terukur.

1.2 Perumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, dapat diidentifikasi beberapa permasalahan utama dalam lokalisasi Premature Ventricular Contraction (PVC) menggunakan analisis sinyal ECG sebagai berikut:

1. Bagaimana mengidentifikasi karakteristik fitur unik yang dihasilkan oleh metode *Higher-Order Statistics* (HOS), *Wavelet Transform*, dan *Power Spectrum Density* (PSD) untuk mendukung lokalisasi PVC pada kelas RVOT dan LVOT secara otomatis?
2. Bagaimana merancang skema fusi fitur yang efektif dari ketiga pendekatan tersebut untuk meningkatkan performa klasifikasi lokalisasi PVC pada kelas RVOT dan LVOT dengan model *Convolutional Neural Network* (CNN)?
3. Sejauh mana perbandingan performa antara pendekatan fitur individual dan berbagai skema kombinasi fitur dalam hal akurasi lokalisasi serta efisiensi komputasi?

1.3 Pernyataan Masalah

Berdasarkan perumusan masalah yang telah diuraikan, pernyataan masalah dalam penelitian ini dapat dirumuskan sebagai berikut:

1. Belum tersedianya arsitektur lokalisasi PVC pada kelas RVOT dan LVOT yang mampu mengintegrasikan kekuatan fitur non-linear (HOS), waktu-frekuensi (*Wavelet*), dan spektral (PSD) secara simultan.
2. Adanya kebutuhan untuk membuktikan secara empiris apakah skema fusi fitur dapat mengatasi keterbatasan metode individual dalam mengenali morfologi PVC yang serupa di segmen ventrikel yang berbeda.
3. Kebutuhan untuk mengukur efektivitas integrasi fitur tersebut terhadap metrik performa (akurasi, presisi, *recall*, F1-score, AUC) serta efisiensi sumber daya pada model berbasis CNN.

1.4 Tujuan

Berdasarkan rumusan dan pernyataan masalah yang telah dipaparkan, penelitian ini difokuskan untuk mencapai target-target utama berikut guna meningkatkan presisi dan efisiensi lokalisasi PVC:

1. Mengembangkan tiga pendekatan ekstraksi fitur berbasis sinyal ECG 12-lead (HOS, PSD, dan *Wavelet*) untuk mendukung lokalisasi PVC pada kelas RVOT dan LVOT secara otomatis.
2. Mengembangkan skema fusi atau kombinasi fitur dari ketiga pendekatan ekstraksi fitur tersebut untuk meningkatkan performa lokalisasi PVC pada kelas RVOT dan LVOT menggunakan CNN.
3. Mengevaluasi dan membandingkan kinerja pendekatan fitur individual dan kombinasi fitur berdasarkan metrik lokalisasi PVC (*accuracy*, *precision*, *recall*, *F1-score*, dan AUC), serta metrik efisiensi seperti waktu komputasi dan penggunaan memori.

1.5 Batasan Masalah

Untuk menjaga fokus penelitian dan memastikan kelayakan teknis dalam pengembangan model, maka ruang lingkup penelitian ini dibatasi pada aspek-aspek berikut:

1. Fokus penelitian hanya pada lokalisasi Premature Ventricular Contraction (PVC).
2. Data yang digunakan adalah sinyal ECG 12-lead dari database publik tervalidasi dengan label lokasi yang jelas.

3. Perbandingan metode hanya mencakup *Higher-Order Statistics*, *Wavelet Transform*, dan *Power Spectrum Density* yang diolah melalui arsitektur *Convolutional Neural Network*.
4. Lokalisasi PVC dalam penelitian ini dibatasi pada klasifikasi lokasi asal PVC ke dalam dua kelas utama, yaitu *Right Ventricular Outflow Tract* (RVOT) dan *Left Ventricular Outflow Tract* (LVOT).
5. Informasi *sublocation* pada dataset digunakan sebagai informasi pendukung untuk memahami karakteristik data, tetapi tidak dijadikan target klasifikasi utama dalam penelitian ini.

1.6 Hipotesis

1. Integrasi fitur berbasis HOS, PSD, dan *Wavelet* ke dalam CNN akan memberikan representasi data yang lebih kaya dibandingkan penggunaan fitur individual, sehingga meningkatkan akurasi lokalisasi PVC pada kelas RVOT dan LVOT.
2. Skema fusi fitur yang mengombinasikan ketiga metode tersebut akan menunjukkan nilai AUC dan F1-Score yang lebih unggul dibandingkan dengan pendekatan fitur tunggal.
3. Meskipun skema fusi meningkatkan kompleksitas komputasi, penggunaan arsitektur CNN yang tepat akan tetap mempertahankan efisiensi waktu komputasi yang dapat diterima untuk kebutuhan analisis klinis.

1.7 Sistematika Penulisan

Proposal penelitian ini disusun dengan sistematika sebagai berikut

1. **BAB I PENDAHULUAN**
Menguraikan latar belakang penelitian mengenai urgensi lokalisasi PVC secara non-invasif, perumusan masalah, pernyataan masalah, tujuan penelitian, batasan masalah, hipotesis, serta sistematika penulisan.
2. **BAB II KAJIAN PUSTAKA**
Menjelaskan riset terkait dan landasan teori pendukung, termasuk sinyal ECG, metode ekstraksi fitur (HOS, *Wavelet*, dan PSD), serta arsitektur CNN.
3. **BAB III METODOLOGI DAN DESAIN SISTEM**
Menjelaskan alur penelitian, metode pengumpulan data, teknik *preprocessing*, skema fusi fitur, arsitektur CNN yang digunakan, serta metrik evaluasi.

4. **BAB IV HASIL DAN PEMBAHASAN**

Menyajikan hasil implementasi, analisis perbandingan kinerja fitur individual versus fusi fitur, serta efektivitas model.

5. **BAB V KESIMPULAN DAN SARAN**

Menyajikan kesimpulan penelitian, validasi hipotesis, kontribusi, keterbatasan, dan saran untuk penelitian lanjutan.

Bab II

Kajian Pustaka

Bab ini menjelaskan riset terkait tugas akhir beserta teori pendukung yang digunakan. Riset terkait diuraikan dalam Sub Bab 2.1, diikuti dengan pembahasan mendalam mengenai sinyal ECG, teknik ekstraksi fitur (PSD, *Wavelet*, dan HOS), arsitektur *Convolutional Neural Network* (CNN), hingga metrik evaluasi. Ringkasan riset disajikan pada bagian terakhir dari Bab 2.

2.1 Penelitian Terkait

Penelitian tentang deteksi dan lokalisasi *Premature Ventricular Contraction* (PVC) telah berkembang dari metode ekstraksi fitur linier konvensional menuju pendekatan berbasis statistik orde tinggi dan pembelajaran mendalam. Berikut adalah 15 penelitian terkait yang menjadi landasan penelitian ini.

Sanchez dkk. mengembangkan metode *electrocardiographic imaging* yang digabungkan dengan *cardiac digital twins* (ECGI-DT) untuk meningkatkan akurasi estimasi asal PVC secara non-invasif. Pendekatan ini memanfaatkan simulasi jantung personal untuk menciptakan basis data PVC sintetis yang luas, sehingga memungkinkan model untuk mempelajari variabilitas sinyal yang kompleks pada pasien dengan kondisi jantung tertentu. Penelitian ini berhasil menunjukkan penurunan rata-rata kesalahan lokalisasi yang signifikan, yaitu dari 30,69 mm menjadi hanya 7,81 mm, yang memberikan bukti kuat mengenai potensi penggunaan kembaran digital dalam perencanaan prosedur ablasi klinis. [2]

Baek dkk. memperkenalkan model berbasis *Transformer* yang dirancang khusus untuk melokalisasi asal PVC ke dalam empat kategori anatomis utama, yaitu LVOT, RVOT, LV Non-OT, dan RV Non-OT. Dengan memanfaatkan mekanisme *self-attention*, model ini mampu menangkap korelasi temporal yang dalam dari sinyal ECG 12-lead secara simultan. Hasil validasi klinis menunjukkan performa yang sangat stabil dengan nilai *macro-average* AUC sebesar 0,915, yang menegaskan bahwa arsitektur *Transformer* memiliki reproduktibilitas tinggi dan sangat efektif untuk tugas klasifikasi spasial non-invasif. [4]

Gao dkk. melakukan deteksi PVC menggunakan algoritma *Random Forest*

yang didasarkan pada ekstraksi 11 parameter fitur morfologi QRS yang sangat terinterpretasi secara klinis. Fitur-fitur yang diekstraksi meliputi tinggi puncak gelombang, lebar durasi, serta parameter kompleks seperti *QR Abs Sum* yang mencerminkan energi total depolarisasi ventrikel. Melalui pengujian pada dataset standar MIT-BIH, penelitian ini berhasil mencapai akurasi sebesar 99,55%, yang menunjukkan bahwa fitur morfologi tradisional yang dikombinasikan dengan algoritma *ensemble learning* masih memiliki relevansi tinggi dalam deteksi aritmia yang presisi. [1]

Bamahel dkk. mengintegrasikan model *2DCNN-GRU* untuk identifikasi akurat terhadap aritmia jantung yang mengancam jiwa. Pendekatan ini melibatkan transformasi sinyal ECG mentah menjadi representasi waktu-frekuensi berupa *scalogram* menggunakan *Continuous Wavelet Transform* (CWT), yang kemudian diproses oleh lapisan konvolusi untuk ekstraksi fitur spasial dan lapisan GRU untuk fitur temporal. Model hibrida ini mencapai akurasi sebesar 97,75% dalam mengklasifikasikan berbagai jenis aritmia *shockable*, membuktikan keunggulan integrasi fitur spasial-temporal dalam analisis sinyal bioelektrik. [3]

Han dkk. mengusulkan sistem klasifikasi aritmia *multiclass* yang memanfaatkan sinyal PPG dari perangkat *smartwatch* yang dikumpulkan dalam kondisi kehidupan nyata. Dengan menggunakan arsitektur model *1D-Bi-GRU*, penelitian ini mengevaluasi kemampuan perangkat *wearable* dalam mendeteksi kejadian PAC dan PVC di luar lingkungan rumah sakit. Hasil penelitian menunjukkan nilai sensitivitas sebesar 83,52% untuk deteksi denyut ektopik, yang memberikan wawasan penting mengenai tantangan *motion artifact* dan variabilitas sinyal dalam pemantauan jantung jangka panjang secara mandiri. [11]

Zhou dkk. melakukan asesmen mendalam terhadap sistem berbasis ECG untuk melokalisasi aritmia ventrikel pada pasien yang menderita penyakit jantung struktural (*Structural Heart Disease*). Sistem ini menggunakan parameter integral QRS dalam jendela waktu 120-ms dari sinyal 12-lead untuk memetakan fokus ektopik. Penelitian ini berhasil membuktikan bahwa algoritma tersebut mampu mencapai akurasi lokalisasi dengan rata-rata kesalahan hanya 5,9 mm pada ruang ventrikel kiri dan kanan, menjadikannya salah satu metode non-invasif paling akurat untuk pasien dengan geometri jantung yang sudah mengalami remodeling. [5]

Novotna dkk. mengusulkan kerangka kerja *Multiple Instance Learning* (MIL) yang berbasis pada arsitektur *1D-CNN* untuk melakukan lokalisasi kontraksi ventrikel prematur. Inovasi utama dari penelitian ini adalah penggunaan anotasi tingkat sinyal secara utuh, sehingga model dapat dilatih tanpa memerlukan label posisi gelombang QRS yang mendetail secara manual. Metode ini mencapai skor *Dice coefficient* sebesar 0,947 dalam mengidentifikasi segmen aritmia, yang menunjukkan efisiensi tinggi dalam pemrosesan dataset berskala

besar dengan beban anotasi yang minimal. [10]

Chashmi dkk. mengembangkan sistem diagnosis aritmia otomatis yang sangat efisien dengan menggabungkan fitur *Discrete Wavelet Transform* (DWT) dan fitur *Higher-Order Statistics* (HOS). Dengan memanfaatkan momen orde tinggi seperti *cumulant*, penelitian ini mampu menangkap karakteristik non-linear dan sifat *non-Gaussian* dari sinyal ECG yang sering kali terabaikan oleh metode spektral biasa. Sistem ini mencapai akurasi klasifikasi yang luar biasa sebesar 99,83% menggunakan pengklasifikasi SVM dengan *kernel* RBF, membuktikan bahwa fitur HOS sangat tangguh terhadap variasi morfologi sinyal. [9]

Zhao dkk. melakukan investigasi mengenai pengaruh denyut ektopik terhadap stabilitas analisis variabilitas detak jantung (HRV). Mereka memperkenalkan metode baru yang disebut *physical threshold-based sample entropy* (Pt-SampEn) untuk mengukur kompleksitas sinyal jantung. Hasil pengujian menunjukkan bahwa Pt-SampEn memiliki ketahanan (*robustness*) yang jauh lebih baik terhadap gangguan dari denyut PVC dibandingkan dengan metode *Sample Entropy* tradisional, sehingga memberikan hasil analisis yang lebih konsisten pada sinyal jantung yang bersifat non-stasioner. [8]

Svehlikova dkk. membandingkan akurasi lokalisasi aktivitas ventrikel prematur menggunakan tiga formulasi sumber titik ekuivalen yang berbeda, yaitu potensial epikardial, tegangan transmembran, dan dipol. Penelitian ini mengevaluasi stabilitas hasil lokalisasi terhadap kesalahan pemodelan geometri dan *noise* pada sinyal ECG. Hasilnya menunjukkan bahwa meskipun terdapat variasi dalam formulasi sumber, lokasi invers yang dihasilkan tetap cukup stabil dan konsisten, memberikan panduan teknis bagi pengembangan algoritma lokalisasi berbasis model fisik. [12]

Singh dkk. menyajikan tinjauan komprehensif mengenai tren ekstraksi fitur sinyal ECG, di mana mereka menekankan bahwa metode dalam domain waktu-frekuensi merupakan pendekatan terbaik saat ini. Hal ini disebabkan oleh kemampuan metode tersebut dalam merepresentasikan informasi penting dari sinyal jantung yang memiliki karakteristik non-linear dan tidak stasioner secara simultan. Tinjauan ini juga menyoroti pentingnya reduksi dimensi dan pemilihan fitur yang efisien untuk meningkatkan performa komputasi pada sistem diagnosis otomatis berbasis AI. [7]

Pradhan dkk. memberikan ulasan mendalam mengenai aplikasi berbagai metode waktu-frekuensi dalam analisis sinyal ECG, termasuk penggunaan DWT, *Stockwell Transform*, dan *Empirical Mode Decomposition* (EMD). Mereka menyoroti bahwa teknik-teknik ini sangat superior dalam melakukan eliminasi derau (*denoising*) tanpa menghilangkan komponen frekuensi penting dari gelombang P, QRS, dan T. Selain itu, ulasan ini menegaskan bahwa visualisasi pola tersembunyi melalui representasi waktu-frekuensi sangat membantu dalam mengidentifikasi kelainan jantung yang halus. [6]

Sayin dkk. meneliti pola indeks bispektral pada sinyal ECG yang abnormal dan membuktikan sensitivitasnya yang tinggi terhadap perubahan fase sinyal. Metrik HOS seperti *bicoherence* mampu mendeteksi interaksi non-linear antara komponen frekuensi yang berbeda, yang merupakan indikasi adanya jalur konduksi yang terganggu pada otot ventrikel. [13]

Prasad dkk. memaparkan kerangka kerja penggunaan *Higher-Order Statistics* khusus untuk analisis sinyal ECG yang bersifat non-linear. Penelitian ini menjelaskan secara mendalam bagaimana statistik orde tinggi dapat mengungkap sifat *non-Gaussian* dari sinyal ektopik, yang menjadi landasan teori utama dalam pemilihan parameter HOS untuk optimasi sistem klasifikasi jantung. [14]

Tysler dkk. melakukan studi mengenai identifikasi lokasi asal PVC secara non-invasif untuk mendukung perencanaan prosedur ablasi kateter. Penelitian ini menegaskan bahwa dengan mengetahui lokasi asal secara presisi sebelum prosedur dimulai, dokter dapat memperpendek waktu pemetaan invasif dan secara signifikan mengurangi risiko komplikasi prosedural bagi pasien. [15]

Berdasarkan narasi 15 penelitian di atas, dapat dilihat dengan jelas ringkasannya melalui Tabel 2.1 berikut.

Tabel 2.1: Ringkasan riset terkait

No.	Judul	Penulis / Tahun	Hasil Riset	Kelebihan	Kekurangan
1	Enhancing PVC localization via cardiac digital twins	Sánchez et al. / 2025	Error lokalisasi turun dari 30,69 mm ke 7,81 mm.	Presi tinggi melalui model simulasi fisik.	Membutuhkan daya komputasi yang sangat masif.
2	AI-guided localization of PVC origins	Baek et al. / 2026	AUC 0,915 menggunakan arsitektur Transformer.	Memiliki nilai reproduksibilitas yang tinggi.	Arsitektur model sangat kompleks untuk real-time.
3	Random Forest-Based ECG PVC Detection	Gao et al. / 2025	Akurasi mencapai tingkat 99,55%.	Fitur sangat terinterpretasi secara klinis.	Terbatas pada deteksi, belum lokalisasi spasial.
4	Advanced integration of 2DCNN-GRU	Ba Mahel et al. / 2024	Akurasi klasifikasi sebesar 97,75%.	Fusi fitur spasial (CNN) dan temporal (GRU).	Memerlukan transformasi CWT yang memakan waktu.
5	Multiclass arrhythmia via smartwatch	Han et al. / 2024	Sensitivitas PAC/PVC mencapai 83,52%.	Dapat diaplikasikan pada perangkat wearable.	Sangat sensitif terhadap motion artifact.
6	Assessment of system for Localizing VT	Zhou et al. / 2021	Akurasi lokalisasi mencapai 5,9 mm.	Performa unggul pada pasien gagal jantung (SHD).	Memerlukan data pemetaan mapping intraprosedural.
7	Deep-Learning PVC Localization	Novotna et al. / 2020	Dice Coefficient mencapai angka 0,947.	Tidak butuh label posisi QRS manual.	Memerlukan dataset tingkat sinyal yang sangat besar.
8	Diagnosis using DWT and HOS features	Chashmi & Amirani / 2019	Akurasi diagnosis otomatis 99,83%.	Fitur HOS tahan terhadap variasi morfologi.	Kompleksitas ekstraksi fitur sangat tinggi.

Tabel 2.1 Ringkasan riset terkait

No.	Judul	Penulis / Tahun	Hasil Riset	Kelebihan	Kekurangan
9	Influence of Ectopic Beats on HRV	Zhao et al. / 2021	Pt-SampEn terbukti jauh lebih stabil.	Sangat robust terhadap noise biologis ektopik.	Memerlukan penentuan threshold fisik yang tepat.
10	Localization using Point Sources	Svehlikova & Tysler / 2016	Error rata-rata berada pada 15,0 - 26,4 mm.	Memiliki stabilitas tinggi pada pengulangan detak.	Terbatas pada asumsi single point generator.
11	ECG feature extraction trends	Singh & Krishnan / 2023	Kompresi data dan reduksi dimensi efisien.	Panduan komprehensif ekstraksi fitur modern.	Kurang mendalam pada bagian optimasi HOS.
12	Review of Time-Frequency Methods	Pradhan et al. / 2023	Efektivitas tinggi pada sinyal non-stasioner.	Mampu memberikan detail hidden pattern sinyal.	Beberapa metode sulit untuk aplikasi real-time.
13	Bispectral index in abnormal ECG	Sayin & Akgun / 2018	HOS mampu mendeteksi interaksi non-linear.	Sensitif terhadap phase coupling sinyal jantung.	Membutuhkan ukuran window analisis yang presisi.
14	HOS for Analysis of Non-linear ECG	Prasad et al. / 2013	Mengungkap kopling fase yang hilang pada PSD.	Kerangka kerja komprehensif untuk non-Gaussian.	Komputasi lebih berat dibanding statistik orde-2.
15	Non-invasive localization of PVC origin	Tysler et al. / 2019	Mengurangi risiko komplikasi prosedural.	Memiliki implikasi klinis yang sangat signifikan.	Akurasi bergantung pada kualitas 12-lead ECG.

2.2 Elektrokardiogram (ECG) dan Fisiologi PVC

2.2.1 Konduksi Jantung Normal vs. Ektopik

Berdasarkan penjelasan dari Singh dan Krishnan (2023), sinyal ECG merupakan rekaman aktivitas kelistrikan jantung yang dipicu secara alami oleh nodus Sinoatrial (SA). Dalam keadaan fisiologis yang normal, impuls listrik akan berjalan melalui jalur konduksi khusus mulai dari Atrium, menuju Nodus AV, Berkas His, hingga berakhir di Serabut Purkinje. Namun, merujuk pada temuan Sánchez et al. (2025) serta Tysler et al. (2019), pada kondisi **Premature Ventricular Contraction (PVC)**, impuls tersebut justru muncul dari titik di luar jalur konduksi normal, yang dikenal sebagai **fokus ektopik** di dalam otot ventrikel. [2, 7, 15]

Menurut ulasan teknis dari Gao et al. (2025), karena impuls PVC ini tidak memanfaatkan jalur konduksi cepat sistem His-Purkinje, maka proses depolarisasi ventrikel terjadi secara lambat melalui jaringan miokardium sel-sel. Hal ini secara langsung menyebabkan manifestasi fisik pada sinyal ECG berupa: [1]

- a) **Pelebaran Kompleks QRS**: Di mana durasi gelombang biasanya akan melebihi angka 120 ms.
- b) **Perubahan Morfologi**: Bentuk gelombang akan tampak abnormal, lebih tajam, atau memiliki lekukan yang tidak biasa tergantung pada lokasi anatomi asal fokus ektopik tersebut.
- c) **Ketiadaan Gelombang P**: Karena atrium tidak didepolarisasi oleh nodus SA pada siklus tersebut, maka gelombang P akan menghilang dari rekaman sinyal.

2.2.2 Signifikansi Klinis Lokalisasi (*Site of Origin*)

Sebagaimana ditekankan dalam penelitian Zhou et al. (2021), penentuan lokasi asal PVC sangat krusial dalam menentukan keberhasilan strategi terapi, khususnya untuk prosedur **Ablasi Kateter**. Penentuan lokasi yang dilakukan secara non-invasif melalui analisis ECG 12-lead sangat membantu dokter dalam memetakan area target sebelum melakukan tindakan invasif. Merujuk pada klasifikasi dari Baek et al. (2026), beberapa titik asal yang sering menjadi target evaluasi meliputi area *Outflow Tracts* (RVOT dan LVOT), area *Annulus*, hingga *Papillary Muscles*. [4, 5]

2.3 Power Spectrum Density (PSD)

2.3.1 Definisi dan Statistik Orde Kedua

Berdasarkan keterangan dari Singh dan Krishnan (2023), PSD merupakan alat analisis dalam domain frekuensi yang digunakan untuk menggambarkan

bagaimana daya dari suatu sinyal didistribusikan di berbagai tingkat frekuensi. Secara statistik, PSD dikategorikan sebagai fungsi statistik orde kedua karena secara matematis merupakan hasil dari Transformasi Fourier terhadap fungsi autokorelasi sinyal tersebut. Secara matematis, PSD dapat didefinisikan sebagai berikut: [7]

$$P_{xx}(f) = \sum_{\tau=-\infty}^{\infty} R_{xx}(\tau)e^{-j2\pi f\tau} \quad (2.1)$$

2.3.2 Estimasi Metode Welch

Menurut Singh dan Krishnan (2023), dalam praktiknya untuk menganalisis ECG, metode Welch sering kali menjadi pilihan utama karena kemampuannya dalam mengurangi varians atau *noise* pada spektrum. Hal ini dicapai melalui pembagian sinyal menjadi beberapa segmen yang saling tumpang tindih (*overlapping*) serta penerapan fungsi jendela (*windowing*). Namun, sebagaimana diungkapkan oleh Pradhan et al. (2023), PSD memiliki keterbatasan mendasar yaitu buta terhadap informasi fasa sinyal, sehingga tidak mampu mendeteksi adanya interaksi fase antar-frekuensi (*phase coupling*) yang sering kali menjadi ciri khas dari sinyal jantung yang abnormal. [6, 7]

2.4 Wavelet Transform (WT)

2.4.1 Multiresolution Analysis (MRA)

Merujuk pada penjelasan Pradhan et al. (2023), sinyal ECG memiliki sifat non-stasioner, yang berarti kandungan atau komponen frekuensinya akan terus berubah seiring dengan berjalannya waktu. *Wavelet Transform* hadir untuk mengatasi keterbatasan dari Transformasi Fourier konvensional dengan cara menggunakan jendela waktu yang fleksibel, yaitu jendela yang sempit untuk komponen frekuensi tinggi dan jendela yang lebar untuk komponen frekuensi rendah. [6]

2.4.2 Discrete Wavelet Transform (DWT)

Berdasarkan ulasan Singh dan Krishnan (2023), metode DWT bekerja dengan memecah sinyal menjadi dua komponen utama, yaitu *Approximation* (A) yang mewakili tren frekuensi rendah dan *Detail* (D) yang menangkap fluktuasi frekuensi tinggi. Menurut Pradhan et al. (2023), dalam konteks lokalisasi PVC, koefisien wavelet pada level dekomposisi tertentu terbukti sangat efektif untuk menangkap morfologi tajam dari kompleks QRS sekaligus mengabaikan gangguan berupa *baseline wander*. Selain itu, sebagaimana dijelaskan oleh Chashmi dan Amirani (2019), penggunaan *Mother Wavelet* dari keluarga **Daubechies** (seperti db4 atau db6) sangat populer karena memiliki kemiripan bentuk dengan pola gelombang kompleks QRS manusia. [6, 7, 9]

2.5 Higher-Order Statistics (HOS)

2.5.1 Melampaui Linearitas dan Gaussianitas

Berdasarkan argumen dari Chashmi dan Amirani (2019), penggunaan statistik konvensional (orde satu dan dua) hanya dianggap cukup apabila kita mendeskripsikan sinyal yang bersifat linear dan Gaussian. Namun, mekanisme fisiologis yang memicu terjadinya aritmia melibatkan dinamika non-linear yang sangat kompleks. Oleh karena itu, penggunaan HOS yang memanfaatkan momen atau *cumulant* orde ketiga menjadi sangat penting untuk mengungkap informasi tersembunyi yang hilang pada analisis spektral biasa. [9]

2.5.2 Bispectrum dan Quadratic Phase Coupling (QPC)

Menurut temuan Chashmi dan Amirani (2019), fitur *Bispectrum* mampu mengukur interaksi antara dua frekuensi (f_1 dan f_2) yang saling berinteraksi secara non-linear untuk menghasilkan komponen frekuensi ketiga ($f_1 + f_2$). Fenomena ini secara teknis dikenal sebagai **Quadratic Phase Coupling (QPC)**. Merujuk pada penelitian Sayin dan Akgun (2018) serta Prasad et al. (2013), interaksi fasa semacam ini terbukti sangat kuat dan memiliki pola yang khas untuk setiap lokasi anatomis PVC yang berbeda. Rumus matematis untuk Bispectrum didefinisikan sebagai berikut: [9, 13, 14]

$$B(f_1, f_2) = \sum_{\tau_1=-\infty}^{\infty} \sum_{\tau_2=-\infty}^{\infty} C_{3x}(\tau_1, \tau_2) e^{-j2\pi(f_1\tau_1 + f_2\tau_2)} \quad (2.2)$$

2.6 Convolutional Neural Network (CNN)

2.6.1 Feature Learning vs. Hand-crafted Features

Berdasarkan penjelasan dari Ba Mahel et al. (2024), keunggulan utama dari CNN dibandingkan dengan algoritma klasifikasi tradisional adalah kemampuannya dalam mempelajari representasi fitur secara hierarkis dan otomatis. Sebagaimana ditambahkan oleh Novotna et al. (2020), struktur arsitektur ini secara umum terdiri dari lapisan konvolusi untuk melakukan deteksi pola, lapisan aktivasi (seperti ReLU) untuk memberikan sifat non-linearitas, serta lapisan *pooling* yang berfungsi untuk mereduksi dimensi spasial dari data. [3, 10]

2.6.2 Arsitektur Multi-Branch untuk Fusi Fitur

Dalam rancangan penelitian ini, merujuk pada konsep yang digunakan oleh Ba Mahel et al. (2024), Han et al. (2024), Chashmi dan Amirani (2019), serta Novotna et al. (2020), digunakan sebuah skema fusi fitur (*Feature Fusion*) yang sangat komprehensif. Skema ini mengombinasikan tiga cabang utama: [3, 9–11]

- a) Cabang PSD yang menggunakan arsitektur 1D-Conv untuk memproses vektor daya spektral.
- b) Cabang Wavelet yang memproses gambar *Scalogram* melalui arsitektur 2D-Conv untuk mengenali tekstur waktu-frekuensi.
- c) Cabang HOS yang memproses nilai Bispectrum untuk menangkap korelasi non-linear yang dalam.

Seluruh fitur dari ketiga cabang tersebut kemudian digabungkan untuk menghasilkan klasifikasi lokasi anatomis PVC dengan tingkat presisi yang lebih tinggi.

2.7 Ringkasan

Bab ini telah membahas landasan penelitian yang digunakan dalam pengembangan model lokalisasi Premature Ventricular Contraction (PVC) berbasis sinyal ECG. Pembahasan diawali dengan uraian mengenai penelitian terkait yang menunjukkan bahwa metode deteksi dan lokalisasi PVC telah berkembang dari pendekatan konvensional berbasis fitur morfologi menuju pendekatan berbasis ekstraksi fitur lanjutan dan pembelajaran mendalam. Beberapa penelitian sebelumnya menunjukkan bahwa metode seperti Wavelet Transform, Higher-Order Statistics (HOS), serta model deep learning seperti CNN memiliki potensi dalam meningkatkan performa analisis sinyal jantung.

Selanjutnya, bab ini menjelaskan konsep dasar Electrocardiogram (ECG) dan karakteristik fisiologis PVC. PVC terjadi akibat munculnya impuls listrik ektopik pada ventrikel, sehingga menghasilkan pola sinyal ECG yang berbeda dari denyut jantung normal. Perbedaan tersebut dapat terlihat pada morfologi kompleks QRS, perubahan bentuk gelombang, serta hilangnya gelombang P pada beberapa kondisi. Oleh karena itu, analisis sinyal ECG menjadi dasar penting dalam proses deteksi dan lokalisasi PVC secara non-invasif.

Bab ini juga membahas tiga pendekatan ekstraksi fitur yang digunakan dalam penelitian, yaitu Power Spectrum Density (PSD), Wavelet Transform, dan Higher-Order Statistics (HOS). PSD digunakan untuk merepresentasikan distribusi daya sinyal dalam domain frekuensi, namun memiliki keterbatasan karena tidak menangkap informasi fase sinyal. Wavelet Transform digunakan untuk menganalisis sinyal ECG yang bersifat non-stasioner melalui representasi waktu-frekuensi. Sementara itu, HOS digunakan untuk menangkap karakteristik non-linear dan non-Gaussian pada sinyal ECG, termasuk hubungan fase antar komponen frekuensi yang tidak dapat dijelaskan oleh statistik orde rendah.

Selain ekstraksi fitur, bab ini juga menjelaskan penggunaan Convolutional Neural Network (CNN) sebagai model klasifikasi. CNN memiliki kemampuan

untuk mempelajari pola fitur secara hierarkis melalui proses konvolusi, aktivasi, pooling, dan klasifikasi. Dalam penelitian ini, CNN digunakan untuk memproses fitur hasil ekstraksi, baik secara individual maupun melalui skema kombinasi fitur. Dengan demikian, CNN berperan sebagai model utama untuk mengevaluasi efektivitas fitur PSD, Wavelet, HOS, serta kombinasi ketiganya dalam mendukung lokalisasi PVC.

Berdasarkan pembahasan pada Bab II, dapat disimpulkan bahwa lokalisasi PVC membutuhkan pendekatan ekstraksi fitur yang mampu merepresentasikan karakteristik sinyal ECG secara komprehensif. PSD memberikan informasi spektral, Wavelet memberikan informasi waktu-frekuensi, sedangkan HOS memberikan informasi non-linear dan hubungan fase. Integrasi ketiga pendekatan tersebut ke dalam model CNN diharapkan dapat menghasilkan sistem lokalisasi PVC yang lebih akurat, terukur, dan dapat dibandingkan performanya secara sistematis pada tahapan metodologi penelitian.

Bab III

Metodologi dan Desain Sistem

3.1 Metode Penelitian


Metode penelitian yang digunakan pada tugas akhir ini adalah metode eksperimen komparatif untuk menguji pengaruh beberapa jenis fitur terhadap performa model CNN dalam lokalisasi PVC. Penelitian dilakukan dengan membangun beberapa skenario input fitur, yaitu fitur tunggal dan kombinasi fitur, lalu membandingkan hasil klasifikasinya menggunakan metrik evaluasi yang telah ditetapkan. Tahapan penelitian dimulai dari studi literatur, pengumpulan dan preprocessing data ECG, ekstraksi fitur, perancangan model CNN, pelatihan model, pengujian, dan analisis hasil.

Penelitian ini tidak berfokus pada pengembangan perangkat keras, melainkan pada pipeline pemrosesan sinyal dan pembelajaran mendalam untuk membuktikan fitur mana yang paling efektif dalam mendukung lokalisasi PVC. Oleh karena itu, setiap skenario fitur akan diuji secara adil dengan prosedur pelatihan dan evaluasi yang sama agar hasil perbandingan dapat dipertanggungjawabkan.

3.1.1 Framework Penelitian

Framework penelitian merupakan alur kerja penelitian yang disusun secara sistematis mulai dari studi literatur hingga diperoleh kesimpulan akhir. Pada penelitian ini, framework digunakan untuk menggambarkan tahapan analisis dan perbandingan efektivitas fitur *Higher-Order Statistics* (HOS), *Wavelet*, dan *Power Spectrum Density* (PSD) dalam model *Convolutional Neural Network* (CNN) untuk lokalisasi *Premature Ventricular Contraction* (PVC).

Berikut penjelasan yang mendetail dari masing-masing tahapan penelitian pada gambar diagram alir *framework* penelitian pada Gambar 3.1:



Gambar 3.1: Diagram Alir *Framework* Penelitian

1. Studi Literatur

Pada tahap ini, penulis melakukan pencarian, pengkajian, dan *review* terhadap penelitian-penelitian sebelumnya yang relevan dengan topik lokalisasi *Premature Ventricular Contraction* (PVC). Penulis mempelajari karakteristik sinyal *Electrocardiogram* (ECG), permasalahan lokalisasi PVC, teori dasar mengenai metode ekstraksi fitur seperti *Higher-Order Statistics* (HOS), *Wavelet*, dan *Power Spectrum Density* (PSD), serta penerapan algoritma *Convolutional Neural Network* (CNN) pada klasifikasi sinyal biologis. Tahap ini sangat penting untuk merangkum fakta, menemukan *state-of-the-art* dari metode penelitian yang diusulkan, dan menganalisis pendekatan untuk merancang sistem yang lebih terarah.

2. Pengumpulan Data

Pada tahap ini, penulis melakukan pengumpulan dan penyiapan data ECG 12-lead yang akan digunakan sebagai bahan utama dalam penelitian. Data tersebut diperoleh secara langsung dari dataset publik yang terpercaya dan sudah memiliki anotasi atau label lokasi PVC yang terverifikasi. Ketersediaan data yang valid dan komprehensif sangat krusial dalam tahap ini karena akan secara langsung memengaruhi keseluruhan proses pelatihan model dan keakuratan prediksi yang dihasilkan. Hasil dari tahap ini adalah kumpulan dataset mentah yang siap untuk masuk ke proses komputasi lebih lanjut.

3. Preprocessing Data

Pada tahap ini, data ECG mentah yang telah dikumpulkan akan melalui proses pembersihan dan penyiapan awal. Penulis melakukan reduksi *noise* atau derau yang mungkin muncul selama perekaman sinyal biologis, serta menyamakan format sinyal agar seragam untuk seluruh data. Proses ini bertujuan untuk meningkatkan kualitas data sinyal jantung sehingga fitur-fitur penting yang merepresentasikan kondisi PVC dapat terekstraksi dengan lebih baik tanpa adanya gangguan. Hasil dari tahap ini adalah dataset sinyal ECG yang telah bersih, terstandarisasi, dan siap untuk diekstraksi.

4. Ekstraksi Fitur

Pada tahap ini, penulis memproses data yang telah melalui *preprocessing* untuk mengekstraksi ciri atau informasi penting menggunakan tiga pendekatan fitur yang berbeda, yaitu HOS, *Wavelet*, dan PSD. Ekstraksi dilakukan baik secara individual untuk masing-masing metode, maupun dalam berbagai skema kombinasi antar fitur. Tujuannya adalah untuk mendapatkan representasi data yang paling informatif yang membedakan karakteristik sinyal dengan sangat baik. Hasil dari tahapan ini adalah matriks fitur komprehensif yang akan menjadi masukan utama (*input*)

bagi model klasifikasi.

5. **Perancangan dan Pelatihan Model CNN**

Pada tahap ini, penulis melakukan perancangan model yang akan dibangun. Perancangan yang dilakukan meliputi penyusunan arsitektur model *Convolutional Neural Network* (CNN) yang akan menerima masukan dari matriks ekstraksi fitur. Setelah dirancang, model dilatih (*training*) dengan menerapkan skenario input fitur tunggal dan kombinasi yang telah diusulkan. Hasil dari tahapan ini adalah model deteksi dan lokalisasi PVC yang paling optimal menggunakan algoritma klasifikasi yang telah mempelajari pola dataset dengan baik.

6. **Pengujian dan Analisis Model yang Dibangun**

Pada tahap ini, penulis melakukan pengujian terhadap performansi dari model CNN yang telah dibangun menggunakan data uji (*test data*). Setiap skenario fitur dievaluasi kinerjanya secara adil dan komprehensif. Pengukuran performa model didasarkan pada metrik evaluasi yang telah ditentukan secara spesifik, yaitu *accuracy*, *precision*, *recall*, *F1-score*, dan *AUC*, serta membandingkannya dari sisi efisiensi waktu komputasi. Hasil akhir penelitian diperoleh melalui analisis perbandingan performa seluruh skenario pengujian untuk menentukan konfigurasi fitur yang paling optimal dalam mendukung lokalisasi PVC.


7. **Penulisan Laporan**

Pada tahap ini penulis menyusun laporan terkait tahapan, pengujian, dan kesimpulan dari penelitian yang dilakukan dengan mengikuti metode perancangan tata tulis ilmiah yang berlaku secara akademis. Hasil dari tahapan ini adalah dokumen buku tugas akhir yang utuh dan komprehensif.

3.1.2 **Metodologi untuk Mencapai Tujuan Penelitian**

A) **Metodologi untuk Mencapai Tujuan Pertama**

Metodologi yang dilakukan dalam mencapai tujuan pertama adalah sebagai berikut:



Gambar 3.2: Diagram Alir Metodologi Tujuan Pertama

Berikut adalah penjelasan untuk setiap tahapan metodologi:

(a) **Pengumpulan Data ECG 12-lead**

Data yang digunakan pada penelitian ini berupa sinyal ECG 12-lead dari dataset publik yang memiliki label lokasi PVC. Data tersebut digunakan sebagai dasar untuk melakukan analisis dan pengujian metode ekstraksi fitur dalam proses lokalisasi PVC.

(b) **Preprocessing Sinyal ECG**

Pada tahap ini dilakukan preprocessing terhadap sinyal ECG untuk mengurangi noise, menormalkan data, dan menyiapkan sinyal agar sesuai untuk proses ekstraksi fitur. Tahap ini penting agar karakteristik sinyal dapat dianalisis dengan lebih baik.

(c) **Ekstraksi Fitur**

Pada tahap ini dilakukan ekstraksi fitur menggunakan tiga pendekatan, yaitu Higher-Order Statistics (HOS), Wavelet Transform, dan Power Spectrum Density (PSD). Setiap metode menghasilkan


representasi fitur yang berbeda sehingga dapat digunakan untuk membandingkan karakteristik informasi yang dihasilkan.

(d) **Hasil Fitur Individual**

Hasil dari tahap ekstraksi fitur berupa tiga jenis fitur individual, yaitu fitur HOS, fitur Wavelet, dan fitur PSD, yang selanjutnya digunakan sebagai masukan pada proses pemodelan CNN.

B) **Metodologi untuk Mencapai Tujuan Kedua**

Metodologi yang dilakukan dalam mencapai tujuan kedua adalah sebagai berikut:



Gambar 3.3: Diagram Alir Metodologi Tujuan Kedua

Berikut adalah penjelasan untuk setiap tahapan metodologi:

(a) **Penyusunan Skenario Kombinasi Fitur**

Pada tahap ini disusun beberapa skenario kombinasi fitur untuk menguji efektivitas fusi fitur dalam lokalisasi PVC. Kombinasi yang digunakan meliputi HOS dan PSD, HOS dan Wavelet, PSD dan Wavelet, serta gabungan ketiga fitur HOS, Wavelet, dan PSD.

(b) **Pelatihan Model CNN**

Setiap skenario kombinasi fitur dimasukkan ke dalam model Convolutional Neural Network (CNN) yang telah dirancang dengan struk-


tur yang sama. Hal ini dilakukan agar perbandingan antar skenario dapat dilakukan secara adil dan objektif.

(c) **Perbandingan Performa Antar Skenario**

Setelah model dilatih, dilakukan perbandingan performa antar skenario untuk mengetahui kombinasi fitur mana yang memberikan hasil terbaik dalam mendukung lokalisasi PVC.

C) **Metodologi untuk Mencapai Tujuan Ketiga**

Metodologi yang dilakukan dalam mencapai tujuan ketiga adalah sebagai berikut:



Gambar 3.4: Diagram Alir Metodologi Tujuan Ketiga

Berikut adalah penjelasan untuk setiap tahapan metodologi:

(a) **Pengujian Model**

Seluruh model yang dihasilkan dari berbagai skenario fitur diuji menggunakan data uji yang sama. Pengujian ini bertujuan untuk memperoleh hasil evaluasi yang konsisten dan dapat dibandingkan antar skenario.

- (b) **Evaluasi Metrik**
Evaluasi dilakukan menggunakan metrik *accuracy*, *precision*, *recall*, *F1-score*, dan *AUC* untuk menilai performa masing-masing model dalam melakukan lokalisasi PVC.
- (c) **Analisis Efisiensi Komputasi**
Selain performa klasifikasi, penelitian ini juga menganalisis efisiensi komputasi berdasarkan waktu pelatihan, waktu inferensi, dan penggunaan memori. Hal ini dilakukan untuk menilai keseimbangan antara akurasi dan efisiensi.
- (d) **Analisis Perbandingan Hasil**
Hasil pengujian dan evaluasi dibandingkan untuk menentukan skenario fitur terbaik berdasarkan keseimbangan antara performa klasifikasi dan efisiensi komputasi.

3.1.3 Analisis Kebutuhan Sistem

A) Spesifikasi Perangkat Keras

- (a) Komputer atau laptop dengan prosesor yang memadai untuk pengolahan data ECG dan pelatihan model CNN.
- (b) Memory minimal 8GB, disarankan 16GB untuk proses komputasi yang lebih stabil.
- (c) Hard drive atau SSD dengan kapasitas yang cukup untuk penyimpanan dataset dan hasil eksperimen.
- (d) GPU opsional untuk mempercepat proses pelatihan model.
- (e) Media penyimpanan eksternal jika diperlukan untuk pencadangan data.

B) Spesifikasi Perangkat Lunak

- (a) Sistem operasi Windows 10/11, Linux, atau macOS.
- (b) Python.
- (c) Jupyter Notebook atau PyCharm IDE.
- (d) Library pengolahan data dan machine learning seperti NumPy, Pandas, SciPy, Matplotlib, Scikit-learn, TensorFlow, atau PyTorch.
- (e) Draw.io untuk pembuatan diagram alir penelitian.

3.1.4 Definisi Lokalisasi PVC

Pada penelitian ini, istilah lokalisasi *Premature Ventricular Contraction* (PVC) mengacu pada proses penentuan lokasi asal atau *site of origin* dari PVC berdasarkan karakteristik sinyal ECG 12-lead. Dengan demikian, lokalisasi yang dimaksud bukan hanya mendeteksi apakah suatu denyut merupakan PVC atau bukan, melainkan mengklasifikasikan sumber kemunculan PVC ke dalam label lokasi anatomis yang tersedia pada dataset.

Secara khusus, penelitian ini menggunakan label lokasi *outflow tract*, yaitu *Right Ventricular Outflow Tract* (RVOT) dan *Left Ventricular Outflow Tract* (LVOT). Model CNN bertugas mempelajari pola fitur dari sinyal ECG untuk memprediksi apakah sumber PVC berasal dari RVOT atau LVOT. Dengan demikian, target klasifikasi utama dalam penelitian ini bersifat biner, yaitu RVOT dan LVOT, bukan klasifikasi seluruh sublokasi anatomis secara lebih rinci.

Dalam konteks evaluasi, prediksi dikatakan benar apabila label lokasi yang diprediksi oleh model sama dengan label sebenarnya pada data. Sebagai contoh, apabila data memiliki label sebenarnya RVOT dan model juga memprediksi RVOT, maka data tersebut dihitung sebagai prediksi benar untuk kelas RVOT. Sebaliknya, apabila data sebenarnya RVOT tetapi model memprediksi LVOT, maka data tersebut dihitung sebagai kesalahan klasifikasi lokasi PVC.

3.1.5 Data

Data yang digunakan dalam penelitian ini adalah data ECG 12-lead dari *dataset* publik Figshare berjudul *A 12-Lead ECG Database to Identify Origins of Idiopathic Ventricular Arrhythmia Containing 334 Patients* [16]. Dataset tersebut berisi rekaman sinyal ECG pasien dengan diagnosis lokasi asal aritmia ventrikel yang telah diverifikasi melalui prosedur ablasi kateter, sehingga dapat digunakan sebagai acuan atau *ground truth* dalam proses klasifikasi lokasi asal aritmia.

Sinyal ECG yang digunakan merupakan ECG 12-lead, yaitu sinyal ECG yang terdiri atas lead I, II, III, aVR, aVL, aVF, V1, V2, V3, V4, V5, dan V6. Dalam penelitian ini, ECG 12-lead berperan sebagai data masukan atau indikator sinyal yang digunakan untuk proses ekstraksi fitur. Sementara itu, label lokasi aritmia diperoleh dari data diagnosis yang memuat atribut *LeftRight* dan *Sublocation*. Dengan demikian, 12-lead ECG tidak berperan sebagai label keluaran model, melainkan sebagai sumber informasi sinyal yang diproses untuk menghasilkan fitur.

Dataset ini terdiri atas data sinyal ECG mentah (*raw ECG*), data ECG hasil reduksi *noise*, serta data diagnosis lokasi RVOT dan LVOT. Pada penelitian ini, eksperimen utama menggunakan data ECG hasil reduksi *noise* sebagai input dalam proses ekstraksi fitur karena sinyal tersebut telah melalui tahap pembersihan sehingga diharapkan menghasilkan representasi fitur yang

lebih stabil. Data ECG mentah digunakan sebagai data pembanding tambahan untuk melihat pengaruh reduksi *noise* terhadap kualitas fitur dan performa model, sedangkan data diagnosis lokasi digunakan sebagai label klasifikasi berdasarkan lokasi asal aritmia.

Secara umum, data yang digunakan dalam penelitian ini mencakup tiga bagian utama. Pertama, *raw ECG*, yaitu sinyal ECG 12-lead mentah yang dapat digunakan sebagai data pembanding dalam proses pengolahan sinyal dan ekstraksi fitur PSD, *Wavelet*, dan HOS. Kedua, *noise-reduced ECG*, yaitu sinyal ECG 12-lead yang telah melalui proses reduksi *noise* dan digunakan sebagai data utama agar fitur yang diekstraksi lebih stabil. Ketiga, data diagnosis lokasi, yaitu data yang memuat informasi jenis aritmia, lokasi umum, dan sublokasi asal aritmia yang digunakan sebagai label dalam proses pelatihan dan evaluasi model.

Berdasarkan data diagnosis lokasi, dataset terdiri atas 334 data pasien yang mencakup dua jenis aritmia ventrikel, yaitu *Premature Ventricular Contraction* (PVC) dan *Ventricular Tachycardia* (VT). Karena penelitian ini berfokus pada lokalisasi PVC, maka data utama yang digunakan dalam proses pelatihan dan evaluasi model dibatasi pada data dengan tipe PVC. Komposisi data berdasarkan jenis aritmia ditunjukkan pada Tabel 3.1.

Tabel 3.1: Komposisi Data Berdasarkan Jenis Aritmia

No.	Jenis Aritmia	Jumlah Data
1	PVC	329
2	VT	5
Total		334

Data diagnosis lokasi memuat beberapa atribut, yaitu *HospitalID*, *Type*, *LeftRight*, *Sublocation*, dan *Gender*. Atribut *HospitalID* digunakan sebagai identitas data pasien, *Type* menunjukkan jenis aritmia, *LeftRight* menunjukkan lokasi asal aritmia secara umum, *Sublocation* menunjukkan lokasi asal aritmia yang lebih spesifik, sedangkan *Gender* menunjukkan jenis kelamin pasien. Pada penelitian ini, atribut *Type* digunakan untuk memilih data PVC, atribut *LeftRight* digunakan sebagai dasar pembentukan label utama RVOT dan LVOT, sedangkan atribut *Sublocation* digunakan untuk melihat rincian lokasi asal aritmia yang lebih spesifik.

Berdasarkan cakupan penelitian, istilah lokalisasi PVC merujuk pada proses penentuan lokasi asal atau *site of origin* PVC berdasarkan sinyal ECG 12-lead. Penelitian ini tidak berfokus pada deteksi apakah suatu sinyal termasuk PVC atau bukan, melainkan pada penentuan lokasi asal PVC. Lokasi asal PVC yang digunakan sebagai target klasifikasi utama adalah lokasi *outflow tract*, yaitu *Right Ventricular Outflow Tract* (RVOT) dan *Left Ventricular Outflow Tract* (LVOT). Dengan demikian, atribut *Sublocation* tidak dijadikan

target klasifikasi utama, tetapi digunakan sebagai informasi pendukung untuk menjelaskan sebaran lokasi asal PVC secara lebih rinci.

Meskipun sinyal ECG yang digunakan terdiri atas 12 lead, label klasifikasi pada penelitian ini tidak didasarkan pada jumlah lead tersebut. ECG 12-lead berperan sebagai data masukan, sedangkan label keluaran model ditentukan berdasarkan atribut lokasi pada data diagnosis. Data dengan nilai *Right* pada atribut *LeftRight* dikategorikan sebagai kelompok RVOT, sedangkan data dengan nilai *Left* dikategorikan sebagai kelompok LVOT sesuai dengan pemetaan label yang digunakan dalam penelitian ini. Distribusi data PVC berdasarkan label lokasi ditunjukkan pada Tabel 3.2.

Tabel 3.2: Distribusi Data PVC Berdasarkan Label Lokasi

No.	Nilai Dataset	Label Penelitian	Jumlah Data	Keterangan
1	Right	RVOT	254	Sisi kanan
2	Left	LVOT	75	Sisi kiri
Total			329	Data PVC

Selain label utama RVOT dan LVOT, data diagnosis juga memuat atribut *Sublocation* yang menunjukkan lokasi asal aritmia secara lebih rinci. Berdasarkan data PVC, terdapat 12 sublokasi yang terisi pada atribut *Sublocation*. Rincian sublokasi PVC berdasarkan label RVOT dan LVOT ditunjukkan pada Tabel 3.3.

Tabel 3.3: Distribusi Data PVC Berdasarkan Sublocation

No.	Label Lokasi	Sublocation	Jumlah Data
1	RVOT	AC	29
2	RVOT	AnteriorSeptal	28
3	RVOT	FreeWall	28
4	RVOT	LC	70
5	RVOT	PosteriorSeptal	32
6	RVOT	RC	24
7	RVOT	RVOTOther	6
8	LVOT	AMC	18
9	LVOT	LCC	37
10	LVOT	LCC-RCC Commissure	7
11	LVOT	RCC	7
12	LVOT	Summit	5
Total Sublocation Terisi			291

Berdasarkan Tabel 3.3, data PVC memiliki 12 sublokasi yang terisi, terdiri atas 7 sublokasi pada kelompok RVOT dan 5 sublokasi pada kelompok LVOT. Namun, terdapat 38 data PVC yang nilai *Sublocation*-nya tidak tercantum pada data diagnosis, yaitu 37 data pada kelompok RVOT dan 1 data pada

kelompok LVOT. Data tersebut tetap dapat digunakan dalam klasifikasi utama RVOT dan LVOT karena atribut *LeftRight* masih tersedia sebagai label utama.

Berdasarkan Tabel 3.2, jumlah data pada kelas RVOT lebih banyak dibandingkan kelas LVOT. Kondisi ini menunjukkan adanya ketidakseimbangan kelas pada dataset, sehingga perlu diperhatikan pada tahap pelatihan model. Ketidakseimbangan kelas dapat menyebabkan model lebih cenderung memprediksi kelas mayoritas, yaitu RVOT. Oleh karena itu, penelitian ini menggunakan pembagian data secara *stratified* agar proporsi kelas RVOT dan LVOT tetap terjaga pada data latih, data validasi, dan data uji. Selain itu, penelitian ini juga mempertimbangkan penggunaan *class weighting* atau metode penyeimbangan data lainnya pada tahap pelatihan model.

Pada proses pelatihan model, setiap data ECG 12-lead dipasangkan dengan label lokasi PVC yang sesuai. Data ECG digunakan sebagai masukan untuk menghasilkan fitur *Power Spectrum Density* (PSD), *Wavelet Transform*, dan *Higher-Order Statistics* (HOS), sedangkan label RVOT atau LVOT digunakan sebagai target klasifikasi. Data kemudian dibagi menjadi data latih, data validasi, dan data uji agar proses pelatihan serta evaluasi model dapat dilakukan secara objektif. Evaluasi model tidak hanya mengandalkan akurasi, tetapi juga memperhatikan metrik yang lebih sesuai untuk data tidak seimbang, seperti *macro-F1*, *balanced accuracy*, performa kelas LVOT, dan *confusion matrix*.

Dengan demikian, data pada penelitian ini memiliki dua peran utama. Pertama, sinyal ECG 12-lead digunakan sebagai sumber informasi utama untuk menghasilkan fitur PSD, *Wavelet*, dan HOS. Kedua, label diagnosis lokasi digunakan untuk mengevaluasi kemampuan model *Convolutional Neural Network* (CNN) dalam melakukan lokalisasi PVC. Keberhasilan model tidak hanya dilihat dari kemampuannya mengenali pola sinyal ECG, tetapi juga dari ketepatannya dalam menentukan lokasi asal PVC sesuai label RVOT atau LVOT.

3.1.6 Posisi Fitur terhadap Model CNN


Pada penelitian ini, fitur yang dibandingkan adalah fitur hasil ekstraksi dari sinyal ECG, yaitu fitur *Higher-Order Statistics* (HOS), fitur *Wavelet Transform*, dan fitur *Power Spectrum Density* (PSD). Ketiga fitur tersebut diperoleh melalui proses ekstraksi fitur sebelum masuk ke tahap pelatihan model CNN.

Dengan demikian, model CNN pada penelitian ini tidak menerima data ECG mentah sebagai masukan utama. Data ECG 12-lead terlebih dahulu melalui tahap *preprocessing* untuk mengurangi *noise*, menyamakan format data, dan menyiapkan sinyal agar lebih sesuai untuk proses analisis. Setelah itu, sinyal ECG yang telah diproses digunakan untuk membentuk representasi fitur HOS, *Wavelet*, dan PSD.

Posisi fitur dalam penelitian ini adalah sebagai masukan atau *input repre-*

sentation bagi model CNN. Artinya, HOS, Wavelet, dan PSD berperan sebagai representasi awal dari sinyal ECG yang menggambarkan karakteristik sinyal dari sudut pandang yang berbeda. Fitur PSD merepresentasikan distribusi daya sinyal pada domain frekuensi, fitur Wavelet merepresentasikan perubahan sinyal dalam domain waktu dan frekuensi, sedangkan fitur HOS merepresentasikan karakteristik statistik orde tinggi yang berkaitan dengan sifat non-linear dan non-Gaussian pada sinyal ECG.

Secara umum, alur posisi fitur terhadap model CNN pada penelitian ini ditunjukkan pada Gambar 3.5.



Gambar 3.5: Alur posisi fitur terhadap model CNN

Berdasarkan Gambar 3.5, dapat dijelaskan bahwa sinyal ECG tidak langsung diklasifikasikan oleh CNN dalam bentuk data mentah. Sinyal ECG terlebih dahulu diolah melalui tahap *preprocessing*, kemudian dilakukan ekstraksi fitur menggunakan PSD, Wavelet, dan HOS. Fitur-fitur tersebut selanjutnya digunakan sebagai masukan CNN untuk melakukan proses pembelajaran pola dan klasifikasi lokasi asal PVC.

Pada skenario fitur tunggal, CNN menerima satu jenis fitur sebagai masukan. Skenario ini terdiri dari tiga percobaan, yaitu CNN dengan input fitur PSD, CNN dengan input fitur Wavelet, dan CNN dengan input fitur HOS. Tujuan dari skenario ini adalah untuk mengetahui efektivitas masing-masing fitur secara individual dalam mendukung lokalisasi PVC.

Pada skenario kombinasi fitur, CNN menerima gabungan dari dua atau tiga jenis fitur. Kombinasi fitur yang digunakan meliputi HOS dan PSD, HOS dan Wavelet, PSD dan Wavelet, serta gabungan HOS, Wavelet, dan PSD. Skenario ini digunakan untuk mengetahui apakah penggabungan beberapa jenis fitur mampu memberikan representasi sinyal yang lebih kaya dibandingkan fitur tunggal.

Skema posisi fitur terhadap model CNN ditunjukkan pada Tabel 3.4.

Tabel 3.4: Posisi Fitur terhadap Model CNN

No.	Tahapan	Keterangan
1	Data ECG 12-lead	Data awal berupa sinyal ECG yang memiliki label lokasi PVC.
2	Preprocessing	Proses pembersihan sinyal, reduksi <i>noise</i> , dan penyesuaian format data.
3	Ekstraksi fitur	Proses pembentukan fitur PSD, Wavelet, dan HOS dari sinyal ECG.
4	Input CNN	CNN menerima hasil ekstraksi fitur sebagai masukan, bukan sinyal ECG mentah secara langsung.
5	Klasifikasi	CNN mempelajari pola dari fitur untuk memprediksi lokasi asal PVC, yaitu RVOT atau LVOT.

Pemilihan CNN pada penelitian ini didasarkan pada kemampuan CNN dalam mempelajari pola lokal dan hierarkis dari data input. Dalam konteks penelitian ini, pola lokal tersebut dapat berupa pola distribusi frekuensi pada fitur PSD, pola waktu-frekuensi pada fitur Wavelet, maupun pola statistik non-linear pada fitur HOS. CNN diharapkan mampu mengenali perbedaan pola fitur yang berkaitan dengan lokasi asal PVC.

Selain itu, CNN juga dapat diterapkan pada skema *feature fusion*. Pada skema tersebut, beberapa jenis fitur dapat digabungkan sebagai input untuk melihat apakah kombinasi informasi spektral, waktu-frekuensi, dan statistik orde tinggi mampu meningkatkan performa lokalisasi PVC. Hal ini sesuai dengan tujuan penelitian yang tidak hanya membandingkan fitur individual, tetapi juga membandingkan beberapa kombinasi fitur.

Walaupun CNN memiliki kebutuhan komputasi yang relatif lebih besar dibandingkan beberapa metode klasifikasi klasik, penelitian ini tetap mempertimbangkan aspek efisiensi komputasi. Oleh karena itu, evaluasi tidak hanya dilakukan berdasarkan metrik performa klasifikasi seperti *accuracy*, *precision*, *recall*, *F1-score*, dan *AUC*, tetapi juga berdasarkan waktu pelatihan, waktu inferensi, dan penggunaan memori. Dengan demikian, pemilihan CNN tidak hanya dinilai dari akurasi prediksi, tetapi juga dari keseimbangan antara performa lokalisasi dan kebutuhan komputasi.

3.1.7 Formulasi Ekstraksi Fitur

Pada penelitian ini, ekstraksi fitur dilakukan untuk mengubah sinyal ECG 12-lead menjadi representasi numerik yang lebih informatif sebelum digunakan sebagai masukan model *Convolutional Neural Network* (CNN). Fitur yang

digunakan terdiri dari *Power Spectrum Density* (PSD), *Wavelet Transform*, dan *Higher-Order Statistics* (HOS). Ketiga fitur tersebut dipilih karena memiliki sudut pandang representasi sinyal yang berbeda, yaitu domain frekuensi, domain waktu-frekuensi, dan karakteristik statistik orde tinggi.

(a) ***Power Spectrum Density* (PSD)**

Power Spectrum Density (PSD) digunakan untuk merepresentasikan distribusi daya atau energi sinyal ECG pada domain frekuensi. PSD dapat digunakan untuk mengetahui komponen frekuensi yang dominan pada sinyal ECG. Secara umum, PSD dapat dinyatakan sebagai transformasi Fourier dari fungsi autokorelasi sinyal.

$$P_{xx}(f) = \sum_{\tau=-\infty}^{\infty} R_{xx}(\tau) e^{-j2\pi f\tau} \quad (3.1)$$

Keterangan:

- (1) $P_{xx}(f)$ adalah nilai *Power Spectrum Density* pada frekuensi f .
- (2) $R_{xx}(\tau)$ adalah fungsi autokorelasi sinyal x pada lag τ .
- (3) f adalah frekuensi.
- (4) τ adalah pergeseran waktu atau *lag*.
- (5) j adalah bilangan imajiner.
- (6) $e^{-j2\pi f\tau}$ adalah komponen eksponensial kompleks pada transformasi Fourier.

Pada penelitian ini, fitur PSD digunakan untuk menangkap karakteristik spektral dari sinyal ECG. Nilai PSD yang tinggi pada frekuensi tertentu menunjukkan bahwa sinyal memiliki daya yang dominan pada frekuensi tersebut. Informasi ini digunakan untuk membantu model dalam membedakan pola sinyal ECG berdasarkan lokasi asal PVC.

(b) ***Wavelet Transform***

Wavelet Transform digunakan untuk merepresentasikan sinyal ECG dalam domain waktu dan frekuensi secara bersamaan. Metode ini sesuai untuk sinyal ECG karena ECG termasuk sinyal non-stasioner, yaitu sinyal yang karakteristik frekuensinya dapat berubah terhadap waktu.

Secara umum, *Continuous Wavelet Transform* (CWT) dapat dituliskan sebagai berikut:

$$W(a, b) = \frac{1}{\sqrt{|a|}} \int_{-\infty}^{\infty} x(t) \psi^* \left(\frac{t-b}{a} \right) dt \quad (3.2)$$

Keterangan:

- (1) $W(a, b)$ adalah koefisien wavelet pada skala a dan translasi b .
- (2) $x(t)$ adalah sinyal ECG dalam domain waktu.
- (3) $\psi^*(t)$ adalah kompleks konjugat dari fungsi *mother wavelet*.
- (4) a adalah parameter skala yang berkaitan dengan informasi frekuensi.
- (5) b adalah parameter translasi yang menunjukkan posisi waktu.
- (6) t adalah variabel waktu.

Pada penelitian ini, fitur Wavelet digunakan untuk menangkap perubahan pola sinyal ECG terhadap waktu dan frekuensi. Nilai koefisien wavelet menunjukkan tingkat kemiripan antara sinyal ECG dan fungsi wavelet pada skala serta waktu tertentu. Representasi ini diharapkan dapat membantu model mengenali pola morfologi sinyal ECG yang berkaitan dengan lokasi asal PVC.

(c) ***Higher-Order Statistics (HOS)***

Higher-Order Statistics (HOS) digunakan untuk menangkap karakteristik statistik orde tinggi dari sinyal ECG. Berbeda dengan statistik orde rendah yang hanya menggambarkan rata-rata dan variansi, HOS dapat memberikan informasi tambahan mengenai bentuk distribusi, ketidaksimetrian, serta sifat non-Gaussian pada sinyal.

Salah satu bentuk HOS yang digunakan untuk merepresentasikan karakteristik sinyal adalah momen orde ke- r , yang dapat dirumuskan sebagai berikut:

$$m_r = E[(x - \mu)^r] \quad (3.3)$$

Keterangan:

- (1) m_r adalah momen orde ke- r .
- (2) $E[\cdot]$ adalah operator nilai harapan atau rata-rata.
- (3) x adalah nilai sampel sinyal ECG.
- (4) μ adalah nilai rata-rata sinyal ECG.
- (5) r adalah orde momen yang digunakan.

Pada penelitian ini, HOS digunakan untuk menangkap karakteristik non-linear dan non-Gaussian pada sinyal ECG. Momen orde tinggi dapat memberikan informasi mengenai pola distribusi sinyal yang tidak dapat

dijelaskan hanya dengan rata-rata dan variansi. Informasi tersebut diharapkan dapat membantu model CNN dalam membedakan karakteristik sinyal PVC berdasarkan lokasi asalnya.

Selain momen orde tinggi, HOS juga dapat direpresentasikan melalui bispectrum untuk mengamati hubungan fase antar komponen frekuensi. Bispectrum dapat dituliskan sebagai berikut:

$$B(f_1, f_2) = E[X(f_1)X(f_2)X^*(f_1 + f_2)] \quad (3.4)$$

Keterangan:

- (1) $B(f_1, f_2)$ adalah nilai bispectrum pada pasangan frekuensi f_1 dan f_2 .
- (2) $X(f_1)$ adalah komponen sinyal pada frekuensi f_1 .
- (3) $X(f_2)$ adalah komponen sinyal pada frekuensi f_2 .
- (4) $X^*(f_1 + f_2)$ adalah kompleks konjugat dari komponen sinyal pada frekuensi gabungan $f_1 + f_2$.
- (5) $E[\cdot]$ adalah operator nilai harapan atau rata-rata.

Bispectrum digunakan untuk melihat adanya hubungan non-linear atau *phase coupling* antar komponen frekuensi pada sinyal ECG. Informasi ini penting karena sinyal PVC dapat memiliki pola non-linear yang tidak dapat direpresentasikan secara penuh oleh fitur berbasis statistik orde rendah atau fitur spektral biasa.

Dengan formulasi tersebut, PSD digunakan untuk menangkap informasi spektral, Wavelet digunakan untuk menangkap informasi waktu-frekuensi, sedangkan HOS digunakan untuk menangkap karakteristik statistik orde tinggi dan non-linear. Ketiga hasil ekstraksi fitur tersebut kemudian digunakan sebagai masukan pada model CNN untuk melakukan klasifikasi lokasi asal PVC, yaitu RVOT dan LVOT.

3.1.8 Pembagian Data dan Validasi Model

Pada penelitian ini, dataset ECG 12-lead yang telah melalui tahap preprocessing akan dibagi menggunakan skema *hold-out* dengan proporsi 80% sebagai data latih dan 20% sebagai data uji. Pembagian data dilakukan secara *stratified* agar proporsi kelas RVOT dan LVOT tetap terjaga pada data latih dan data uji. Data latih digunakan untuk proses pelatihan dan validasi model, sedangkan data uji digunakan sebagai data akhir untuk mengevaluasi kemampuan generalisasi model terhadap data yang belum pernah dilihat sebelumnya.

Untuk memperoleh hasil evaluasi yang lebih stabil, data latih sebesar 80% akan divalidasi menggunakan metode *K-Fold Cross Validation* dengan nilai

$K = 5$. Pada skema ini, data latih dibagi menjadi lima bagian, di mana empat bagian digunakan sebagai data pelatihan dan satu bagian digunakan sebagai data validasi secara bergantian. Nilai performansi dari setiap fold kemudian dirata-ratakan untuk memperoleh skor validasi yang lebih representatif.

Skema pembagian data dan validasi ini digunakan agar setiap model yang diuji, baik model baseline maupun model usulan, memperoleh prosedur evaluasi yang sama. Dengan demikian, hasil perbandingan antar skenario fitur dapat dilakukan secara lebih objektif dan dapat dipertanggungjawabkan. Selain itu, untuk mencegah terjadinya *data leakage*, seluruh proses normalisasi, scaling, penanganan ketidakseimbangan data, pemilihan fitur, dan *hyperparameter tuning* dilakukan hanya pada data latih atau pada *fold training*. Data uji tidak digunakan dalam proses pelatihan maupun pemilihan parameter, tetapi hanya digunakan untuk evaluasi akhir model.

3.1.9 Metrik Uji

Metrik pengujian yang digunakan dalam penelitian ini mengacu pada standar evaluasi klasifikasi medis untuk menilai kemampuan model *Convolutional Neural Network* (CNN) dalam melakukan lokalisasi sumber *Premature Ventricular Contraction* (PVC). Evaluasi dilakukan berdasarkan kesesuaian antara hasil prediksi model dan label lokasi sebenarnya pada dataset. Label lokasi yang digunakan dalam penelitian ini adalah *Right Ventricular Outflow Tract* (RVOT) dan *Left Ventricular Outflow Tract* (LVOT).

Pada penelitian ini, evaluasi tidak hanya dimaknai sebagai proses membedakan denyut PVC dan non-PVC, tetapi diarahkan pada ketepatan model dalam menentukan lokasi asal PVC. Sebagai contoh, apabila suatu data memiliki label sebenarnya RVOT dan model memprediksi RVOT, maka prediksi tersebut dianggap benar. Sebaliknya, apabila data memiliki label sebenarnya RVOT tetapi model memprediksi LVOT, maka prediksi tersebut dianggap salah karena model gagal menentukan lokasi asal PVC dengan tepat.

Dalam perhitungan metrik evaluasi, terdapat empat parameter utama yang digunakan, yaitu *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN). Karena penelitian ini berfokus pada lokalisasi PVC, maka definisi keempat parameter tersebut disesuaikan dengan kelas lokasi tertentu. Untuk suatu kelas lokasi k , misalnya RVOT, definisinya adalah sebagai berikut:

- (a) **TP (*True Positive*)**: jumlah data dengan label sebenarnya kelas k dan model juga memprediksi data tersebut sebagai kelas k .
- (b) **TN (*True Negative*)**: jumlah data yang bukan berasal dari kelas k dan model juga tidak memprediksi data tersebut sebagai kelas k .
- (c) **FP (*False Positive*)**: jumlah data yang sebenarnya bukan kelas k , tetapi model memprediksi data tersebut sebagai kelas k .

- (d) **FN (*False Negative*)**: jumlah data yang sebenarnya termasuk kelas k , tetapi model memprediksi data tersebut sebagai kelas lain.

Interpretasi yang sama juga berlaku apabila kelas LVOT dijadikan sebagai kelas positif. Dengan demikian, TP, TN, FP, dan FN pada penelitian ini digunakan untuk menilai benar atau salahnya prediksi lokasi PVC, bukan hanya untuk membedakan denyut normal dan denyut PVC.

Metrik yang digunakan dalam penelitian ini meliputi *accuracy*, *precision*, *recall* atau *sensitivity*, *specificity*, *F1-score*, *macro-F1*, *balanced accuracy*, *Area Under Curve* (AUC), dan *confusion matrix*. Selain itu, karena jumlah data RVOT lebih banyak dibandingkan LVOT, evaluasi juga memperhatikan nilai *precision* dan *recall* pada kelas LVOT sebagai kelas minoritas. Berikut adalah rumus, keterangan, dan interpretasi dari masing-masing metrik:

(a) **Akurasi (*Accuracy*)**

Akurasi digunakan untuk mengukur proporsi jumlah prediksi lokasi PVC yang benar terhadap seluruh data yang diuji.

$$accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.5)$$

Keterangan:

- (1) TP adalah jumlah data kelas lokasi tertentu yang diprediksi benar sebagai kelas tersebut.
- (2) TN adalah jumlah data bukan kelas lokasi tertentu yang juga diprediksi bukan sebagai kelas tersebut.
- (3) FP adalah jumlah data bukan kelas lokasi tertentu tetapi salah diprediksi sebagai kelas tersebut.
- (4) FN adalah jumlah data kelas lokasi tertentu tetapi salah diprediksi sebagai kelas lain.

Semakin tinggi nilai akurasi, maka semakin besar proporsi data yang berhasil diklasifikasikan ke lokasi PVC yang benar. Namun, karena data RVOT dan LVOT memiliki jumlah yang tidak seimbang, akurasi tidak digunakan sebagai satu-satunya dasar penilaian performa model.

(b) **Presisi (*Precision*)**

Presisi digunakan untuk mengukur ketepatan model ketika memprediksi suatu kelas lokasi PVC tertentu.

$$precision = \frac{TP}{TP + FP} \quad (3.6)$$

Keterangan:

- (1) TP adalah jumlah data kelas lokasi tertentu yang berhasil diprediksi dengan benar.
- (2) FP adalah jumlah data yang sebenarnya bukan kelas lokasi tersebut, tetapi salah diprediksi sebagai kelas tersebut.

Semakin tinggi nilai presisi, maka semakin kecil kemungkinan model salah memprediksi data kelas lain sebagai kelas lokasi yang sedang dievaluasi. Pada penelitian ini, presisi kelas LVOT juga diperhatikan untuk mengetahui seberapa tepat model ketika memprediksi kelas LVOT sebagai kelas minoritas.

(c) **Sensitiviti atau *Recall***

Sensitiviti atau *recall* digunakan untuk mengukur kemampuan model dalam mengenali seluruh data yang benar-benar berasal dari suatu kelas lokasi PVC.

$$sensitivity = recall = \frac{TP}{TP + FN} \quad (3.7)$$

Keterangan:

- (1) TP adalah jumlah data kelas lokasi tertentu yang berhasil diprediksi dengan benar.
- (2) FN adalah jumlah data kelas lokasi tertentu yang gagal dikenali dan diprediksi sebagai kelas lain.

Semakin tinggi nilai *recall*, maka semakin baik kemampuan model dalam mengenali seluruh data dari kelas lokasi tertentu. Pada penelitian ini, nilai *recall* kelas LVOT menjadi salah satu perhatian utama karena LVOT memiliki jumlah data lebih sedikit dibandingkan RVOT.

(d) **Spesifisiti (*Specificity*)**

Spesifisiti digunakan untuk mengukur kemampuan model dalam mengenali data yang bukan termasuk kelas lokasi tertentu.

$$specificity = \frac{TN}{TN + FP} \quad (3.8)$$

Keterangan:

- (1) TN adalah jumlah data yang bukan kelas lokasi tertentu dan benar diprediksi bukan sebagai kelas tersebut.

- (2) *FP* adalah jumlah data yang bukan kelas lokasi tertentu tetapi salah diprediksi sebagai kelas tersebut.

Semakin tinggi nilai spesifisiti, maka semakin baik model dalam menghindari kesalahan prediksi terhadap kelas lokasi tertentu.

(e) ***F1-score***

F1-score digunakan untuk mengukur keseimbangan antara *precision* dan *recall*. Metrik ini penting digunakan apabila terdapat ketidakseimbangan jumlah data antar kelas.

$$F1\text{-score} = 2 \times \frac{\textit{precision} \times \textit{recall}}{\textit{precision} + \textit{recall}} \quad (3.9)$$

Keterangan:

- (1) *precision* adalah tingkat ketepatan model ketika memprediksi suatu kelas lokasi PVC.
- (2) *recall* adalah kemampuan model dalam mengenali seluruh data yang benar-benar berasal dari kelas lokasi tertentu.

Semakin tinggi nilai *F1-score*, maka semakin baik keseimbangan antara ketepatan prediksi dan kemampuan model dalam mengenali data dari suatu kelas lokasi PVC.

(f) ***Macro-F1***

Macro-F1 digunakan untuk menghitung rata-rata nilai *F1-score* dari setiap kelas dengan bobot yang sama. Metrik ini penting digunakan pada data tidak seimbang karena tidak membuat kelas mayoritas RVOT mendominasi hasil evaluasi.

$$\textit{macro-F1} = \frac{F1_{RVOT} + F1_{LVOT}}{2} \quad (3.10)$$

Keterangan:

- (1) $F1_{RVOT}$ adalah nilai *F1-score* untuk kelas RVOT.
- (2) $F1_{LVOT}$ adalah nilai *F1-score* untuk kelas LVOT.

Semakin tinggi nilai *macro-F1*, maka semakin baik performa model dalam mengenali kedua kelas secara seimbang, baik kelas mayoritas maupun kelas minoritas.

(g) **Balanced Accuracy**

Balanced accuracy digunakan untuk mengukur rata-rata kemampuan model dalam mengenali setiap kelas. Metrik ini lebih sesuai digunakan pada dataset yang tidak seimbang dibandingkan akurasi biasa.

$$\text{balanced accuracy} = \frac{\text{recall}_{RVOT} + \text{recall}_{LVOT}}{2} \quad (3.11)$$

Keterangan:

- (1) recall_{RVOT} adalah kemampuan model dalam mengenali data yang benar-benar berasal dari kelas RVOT.
- (2) recall_{LVOT} adalah kemampuan model dalam mengenali data yang benar-benar berasal dari kelas LVOT.

Semakin tinggi nilai *balanced accuracy*, maka semakin baik kemampuan model dalam mengenali kedua kelas secara proporsional.

(h) **Area Under Curve (AUC)**

AUC digunakan untuk mengukur kemampuan model dalam membedakan kelas lokasi PVC berdasarkan nilai probabilitas prediksi. AUC diperoleh dari kurva ROC yang menggambarkan hubungan antara *True Positive Rate* (TPR) dan *False Positive Rate* (FPR).

$$TPR = \frac{TP}{TP + FN} \quad (3.12)$$

$$FPR = \frac{FP}{FP + TN} \quad (3.13)$$

Keterangan:

- (1) TPR atau *True Positive Rate* menunjukkan proporsi data kelas lokasi tertentu yang berhasil dikenali dengan benar.
- (2) FPR atau *False Positive Rate* menunjukkan proporsi data bukan kelas lokasi tertentu yang salah diprediksi sebagai kelas tersebut.
- (3) TP adalah jumlah data kelas lokasi tertentu yang diprediksi benar.
- (4) FN adalah jumlah data kelas lokasi tertentu yang salah diprediksi sebagai kelas lain.
- (5) FP adalah jumlah data kelas lain yang salah diprediksi sebagai kelas lokasi tertentu.

- (6) TN adalah jumlah data kelas lain yang benar diprediksi bukan sebagai kelas lokasi tertentu.

Nilai AUC berada pada rentang 0 hingga 1. Semakin mendekati 1, maka semakin baik kemampuan model dalam membedakan kelas lokasi PVC, yaitu RVOT dan LVOT.

(i) ***Confusion Matrix***

Confusion matrix digunakan untuk menampilkan jumlah prediksi benar dan salah pada setiap kelas lokasi PVC. Melalui *confusion matrix*, dapat diketahui berapa banyak data RVOT yang benar diprediksi sebagai RVOT, berapa banyak data RVOT yang salah diprediksi sebagai LVOT, berapa banyak data LVOT yang benar diprediksi sebagai LVOT, dan berapa banyak data LVOT yang salah diprediksi sebagai RVOT.

Metrik ini penting digunakan karena dapat memperlihatkan pola kesalahan model secara lebih jelas, terutama pada kelas LVOT yang memiliki jumlah data lebih sedikit. Dengan demikian, *confusion matrix* membantu memastikan apakah model benar-benar mampu mengenali kedua kelas atau hanya cenderung memprediksi kelas mayoritas.

Dengan penggunaan metrik tersebut, evaluasi model CNN pada penelitian ini diharapkan dapat memberikan gambaran yang lebih lengkap mengenai kemampuan model dalam melakukan lokalisasi PVC. Evaluasi tidak hanya dilihat dari akurasi keseluruhan, tetapi juga dari kemampuan model dalam mengenali masing-masing lokasi asal PVC secara objektif. Karena distribusi data RVOT dan LVOT tidak seimbang, hasil evaluasi juga dianalisis berdasarkan *macro-F1*, *balanced accuracy*, nilai *precision* dan *recall* pada kelas LVOT, serta *confusion matrix*.

3.1.10 Model Baseline

Model baseline merupakan model awal yang digunakan sebagai acuan pembandingan sebelum diterapkan skenario pengembangan lebih lanjut. Dalam penelitian ini, model baseline dibangun menggunakan arsitektur Convolutional Neural Network (CNN) sederhana dengan parameter awal atau parameter default. Model ini digunakan untuk mengetahui performa dasar CNN dalam melakukan lokalisasi Premature Ventricular Contraction (PVC) berdasarkan fitur sinyal ECG yang digunakan.

Pada tahap baseline, model belum menerapkan hyperparameter tuning, balancing data, maupun teknik optimasi lanjutan lainnya. Hal ini bertujuan agar performa awal CNN dapat diketahui secara murni sebelum dilakukan peningkatan model. Dengan demikian, baseline berfungsi sebagai titik awal


untuk mengukur apakah metode pengembangan berikutnya, seperti kombinasi fitur, penanganan ketidakseimbangan data, atau hyperparameter tuning, benar-benar memberikan peningkatan performa terhadap model.

Proses baseline dimulai dari total dataset yang dibagi menggunakan skema hold-out, yaitu 80% sebagai data training dan 20% sebagai data testing. Data training digunakan untuk proses pelatihan dan validasi model, sedangkan data testing disimpan sebagai data uji akhir yang tidak dilibatkan dalam proses pelatihan. Tujuan pemisahan data testing adalah untuk menguji kemampuan generalisasi model terhadap data baru yang belum pernah dilihat sebelumnya.

Pada data training sebesar 80%, dilakukan proses validasi menggunakan metode K-Fold Cross Validation dengan nilai $K = 5$. Pada skema ini, data training dibagi menjadi lima bagian. Pada setiap iterasi, empat bagian digunakan sebagai data sub-training, sedangkan satu bagian digunakan sebagai data validasi. Proses ini dilakukan secara bergantian hingga seluruh bagian data pernah menjadi data validasi.

Pada setiap fold, model CNN baseline dilatih menggunakan data sub-training, kemudian dievaluasi menggunakan data validasi. Nilai performa dari setiap fold dicatat, kemudian dihitung rata-ratanya untuk memperoleh skor validasi baseline. Skor ini digunakan sebagai gambaran awal kemampuan model CNN sederhana sebelum dilakukan tahap pengembangan lebih lanjut.

Setelah proses validasi selesai, model CNN baseline dilatih ulang menggunakan seluruh 80% data training. Tahap pelatihan ulang ini dilakukan agar model baseline final memperoleh informasi yang lebih lengkap dari seluruh data latih. Model baseline final kemudian diuji menggunakan 20% data testing untuk menghasilkan metrik evaluasi akhir, seperti akurasi, presisi, recall, F1-score, dan AUC. Alur proses pembuatan model CNN baseline ditunjukkan pada Gambar 3.6.



Gambar 3.6: Pipeline pembuatan model CNN baseline

Berdasarkan Gambar 3.6, model baseline dibangun melalui beberapa tahapan utama, yaitu pembagian dataset, validasi menggunakan 5-Fold Cross Validation, pelatihan model CNN sederhana, pencatatan skor validasi baseline, pelatihan ulang menggunakan seluruh data training, dan evaluasi akhir menggunakan data testing. Hasil dari tahap baseline ini selanjutnya digunakan sebagai pembandingan terhadap model usulan yang melibatkan fitur PSD,

Wavelet, HOS, maupun kombinasi ketiganya.

3.1.11 Hyperparameter Tuning Model CNN

Setelah model baseline diperoleh, tahap selanjutnya adalah melakukan *hyperparameter tuning* untuk meningkatkan performa model CNN. *Hyperparameter tuning* dilakukan dengan mencari kombinasi parameter yang paling optimal berdasarkan hasil validasi model. Tahap ini bertujuan untuk memperoleh konfigurasi model CNN yang mampu menghasilkan performa lebih baik dibandingkan model baseline.

Pada penelitian ini, proses *hyperparameter tuning* dilakukan menggunakan data training dengan skema validasi yang sama seperti model baseline, yaitu 5-Fold Cross Validation. Setiap kombinasi parameter diuji terhadap data validasi, kemudian kombinasi dengan hasil performa terbaik dipilih sebagai konfigurasi model akhir. Parameter yang diuji dalam proses *hyperparameter tuning* ditunjukkan pada Tabel 3.5.

Tabel 3.5: Parameter yang diuji pada proses *hyperparameter tuning* CNN

Hyperparameter	Nilai yang Diuji	Keterangan
Learning rate	0.001, 0.0005, 0.0001	Menentukan besar langkah pembaruan bobot pada saat proses pelatihan model.
Batch size	16, 32, 64	Menentukan jumlah data yang diproses dalam satu iterasi pelatihan.
Jumlah epoch	50, 100, 150	Menentukan jumlah pengulangan proses pelatihan terhadap seluruh data training.
Jumlah filter konvolusi	32, 64, 128	Menentukan banyaknya filter yang digunakan untuk mengekstraksi pola dari input fitur.
Ukuran kernel	3, 5	Menentukan ukuran jendela konvolusi untuk menangkap pola lokal pada data.
Dropout rate	0.2, 0.3, 0.5	Digunakan untuk mengurangi risiko <i>overfitting</i> selama proses pelatihan.
Optimizer	Adam, RMSprop	Digunakan untuk mengatur proses optimasi bobot model selama pelatihan.
Fungsi aktivasi	ReLU	Digunakan untuk memberikan sifat non-linear pada model CNN.

Berdasarkan Tabel 3.5, proses tuning dilakukan dengan menguji beberapa kombinasi parameter yang berpengaruh terhadap proses pelatihan model CNN. Parameter seperti *learning rate*, *batch size*, jumlah filter, ukuran kernel, dan *dropout rate* dipilih karena dapat memengaruhi kemampuan model dalam mempelajari pola fitur sinyal ECG.

Hasil dari setiap kombinasi hyperparameter kemudian dibandingkan berdasarkan metrik evaluasi validasi, seperti akurasi, presisi, recall, F1-score, dan AUC. Kombinasi parameter dengan performa terbaik akan digunakan untuk melatih model akhir menggunakan seluruh data training. Model hasil tuning kemudian diuji menggunakan data testing untuk mengetahui apakah tuning mampu meningkatkan performa dibandingkan model baseline.

3.1.12 Penanganan Ketidakseimbangan Data

Ketidakseimbangan data merupakan salah satu permasalahan yang sering terjadi pada penelitian klasifikasi medis, termasuk pada klasifikasi lokalisasi *Premature Ventricular Contraction* (PVC). Ketidakseimbangan data terjadi apabila jumlah sampel pada setiap kelas lokasi PVC tidak merata. Pada penelitian ini, data PVC memiliki distribusi kelas yang tidak seimbang, yaitu jumlah data RVOT lebih banyak dibandingkan LVOT. Kondisi ini dapat menyebabkan model CNN lebih cenderung mengenali kelas mayoritas, yaitu RVOT, sedangkan kelas minoritas, yaitu LVOT, berisiko memiliki performa klasifikasi yang lebih rendah.

Pada penelitian ini, penanganan ketidakseimbangan data dilakukan hanya pada data latih atau pada *fold training* dalam proses validasi. Data uji tidak dilakukan proses *balancing* agar tetap merepresentasikan kondisi data asli dan dapat digunakan untuk menguji kemampuan generalisasi model secara objektif. Dengan demikian, hasil evaluasi akhir yang diperoleh dari data uji dapat menggambarkan performa model terhadap data baru yang belum pernah dilihat sebelumnya.

Tahapan awal penanganan ketidakseimbangan data dilakukan dengan menganalisis distribusi jumlah sampel pada setiap kelas. Analisis ini bertujuan untuk mengetahui perbedaan jumlah data antara kelas RVOT dan LVOT. Apabila ditemukan ketidakseimbangan jumlah data yang cukup signifikan, maka dilakukan strategi penanganan agar proses pelatihan model menjadi lebih adil terhadap kedua kelas.

Strategi utama yang digunakan dalam penelitian ini adalah penerapan *class weight* pada proses pelatihan model CNN. *Class weight* memberikan bobot yang lebih besar pada kelas minoritas dan bobot yang lebih kecil pada kelas mayoritas. Dengan cara ini, kesalahan prediksi pada kelas minoritas akan mendapatkan penalti yang lebih besar, sehingga model terdorong untuk mempelajari pola dari kelas LVOT dengan lebih baik.

Secara umum, nilai *class weight* dapat dihitung berdasarkan perbandingan

antara jumlah total data latih dan jumlah data pada setiap kelas. Semakin sedikit jumlah sampel pada suatu kelas, maka semakin besar bobot yang diberikan pada kelas tersebut. Perhitungan *class weight* dapat dirumuskan sebagai berikut:

$$w_i = \frac{N}{K \times n_i} \quad (3.14)$$

dengan w_i merupakan bobot untuk kelas ke- i , N merupakan jumlah seluruh data latih, K merupakan jumlah kelas, dan n_i merupakan jumlah data latih pada kelas ke- i .

Penerapan *class weight* dilakukan pada tahap pelatihan model, baik pada model baseline maupun model hasil pengembangan. Pada proses *K-Fold Cross Validation*, perhitungan *class weight* dilakukan hanya berdasarkan data pada *fold training*, bukan pada keseluruhan data. Hal ini dilakukan untuk mencegah terjadinya *data leakage*, sehingga informasi dari data validasi maupun data uji tidak ikut memengaruhi proses pelatihan model.

Hasil model dengan *class weight* tetap dibandingkan dengan model baseline awal agar dapat diketahui apakah penanganan ketidakseimbangan data memberikan peningkatan performa. Peningkatan performa tidak hanya diamati melalui nilai akurasi, tetapi juga melalui metrik lain seperti *precision*, *recall*, *F1-score*, *macro-F1*, *balanced accuracy*, AUC, dan *confusion matrix*. Hal ini penting karena pada data yang tidak seimbang, nilai akurasi saja belum cukup untuk menggambarkan kemampuan model dalam mengenali seluruh kelas.

Selain itu, evaluasi juga memperhatikan performa kelas LVOT sebagai kelas minoritas. Nilai *precision* LVOT dan *recall* LVOT digunakan untuk melihat apakah model mampu memprediksi kelas LVOT secara tepat dan mengenali data LVOT dengan baik. Dengan demikian, model tidak hanya dinilai berdasarkan performa keseluruhan, tetapi juga berdasarkan kemampuannya dalam mengenali kelas minoritas.

Dengan adanya penanganan ketidakseimbangan data, model CNN diharapkan mampu mempelajari pola dari setiap kelas lokasi PVC secara lebih proporsional. Strategi ini juga bertujuan untuk mengurangi kemungkinan model terlalu berpihak pada kelas mayoritas, sehingga hasil klasifikasi lokalisasi PVC dapat menjadi lebih stabil dan representatif.

3.1.13 Explainable Artificial Intelligence (XAI)

Explainable Artificial Intelligence (XAI) merupakan pendekatan yang digunakan untuk memberikan penjelasan terhadap hasil prediksi model kecerdasan buatan. Pada penelitian ini, XAI diterapkan untuk membantu memahami bagaimana model CNN mengambil keputusan dalam melakukan lokalisasi Premature Ventricular Contraction (PVC). Penerapan XAI penting karena model deep learning seperti CNN sering dianggap sebagai model *black box*, yaitu

model yang mampu menghasilkan prediksi tetapi proses pengambilan keputusannya sulit dipahami secara langsung.

Dalam konteks penelitian ini, XAI digunakan untuk mengetahui fitur atau bagian input yang paling berkontribusi terhadap hasil klasifikasi model. Hal ini penting karena penelitian tidak hanya bertujuan untuk memperoleh nilai performa yang tinggi, tetapi juga untuk menganalisis kontribusi fitur Higher Order Statistics (HOS), Wavelet, dan Power Spectrum Density (PSD) dalam mendukung proses lokalisasi PVC. Dengan adanya XAI, hasil prediksi model CNN dapat dianalisis secara lebih jelas dan dapat dipertanggungjawabkan secara ilmiah.

Metode XAI yang dapat digunakan dalam penelitian ini adalah *feature importance* atau SHAP (*SHapley Additive exPlanations*). Metode *feature importance* digunakan untuk mengetahui fitur mana yang memiliki pengaruh besar terhadap hasil prediksi model. Sementara itu, SHAP digunakan untuk menjelaskan kontribusi setiap fitur terhadap keputusan model berdasarkan nilai kontribusi positif atau negatif pada suatu prediksi.

Penerapan XAI dilakukan setelah model CNN selesai dilatih dan diuji. Model yang telah menghasilkan performa terbaik digunakan sebagai objek analisis XAI. Input fitur yang dianalisis dapat berupa fitur PSD, Wavelet, HOS, maupun kombinasi dari ketiganya. Hasil analisis XAI kemudian digunakan untuk melihat apakah fitur tertentu memiliki pengaruh dominan terhadap klasifikasi lokasi PVC.

Secara umum, tahapan penerapan XAI dalam penelitian ini adalah sebagai berikut:

1. Menentukan model CNN terbaik berdasarkan hasil evaluasi metrik performa.
2. Memasukkan data uji atau sampel representatif ke dalam model CNN yang telah dilatih.
3. Menghitung kontribusi fitur menggunakan metode XAI, seperti *feature importance* atau SHAP.
4. Memvisualisasikan kontribusi fitur untuk mengetahui bagian input yang paling memengaruhi hasil prediksi.
5. Menganalisis hasil visualisasi untuk menjelaskan hubungan antara fitur yang digunakan dan keputusan klasifikasi model.

Hasil dari XAI dapat berupa visualisasi kontribusi fitur, seperti grafik peringkat fitur atau plot nilai SHAP. Visualisasi tersebut digunakan untuk menunjukkan fitur mana yang paling berpengaruh dalam proses klasifikasi. Jika fitur

HOS, Wavelet, atau PSD menunjukkan kontribusi yang besar, maka hal tersebut dapat memperkuat analisis bahwa fitur tersebut memiliki peran penting dalam membedakan karakteristik lokasi PVC.

Dengan menerapkan XAI, penelitian ini tidak hanya mengevaluasi performa model berdasarkan nilai akurasi, precision, recall, F1-score, dan AUC, tetapi juga memberikan interpretasi terhadap keputusan model. Oleh karena itu, XAI berperan sebagai pendukung analisis agar model CNN yang dibangun tidak hanya akurat, tetapi juga lebih mudah dipahami dan dijelaskan.

3.1.14 Metode Pengujian

Untuk mengetahui keberhasilan seluruh rancangan sistem dan model yang telah dikembangkan, diperlukan adanya tahap pengujian yang komprehensif, baik dari sisi efektivitas ekstraksi fitur maupun performansi algoritma klasifikasi. Pengujian ini ditujukan untuk memvalidasi apakah integrasi berbagai domain fitur mampu mencapai tujuan tugas akhir ini dalam melokalisasi titik asal PVC secara presisi.

Tujuan Pengujian

Tujuan utama dari pengujian ini adalah untuk membuktikan tingkat akurasi dan keandalan dari algoritma ekstraksi ciri berbasis statistik orde tinggi, transformasi waktu-frekuensi, dan spektral daya. Selain itu, pengujian ini dirancang untuk menganalisis kontribusi masing-masing fitur, baik secara individual maupun melalui skema fusi fitur, dalam mendukung model *Convolutional Neural Network* (CNN) untuk menentukan lokasi anatomis fokus ektopik pada ventrikel jantung.

Skenario Pengujian

Berdasarkan kerangka penelitian yang telah disusun, pengujian dilakukan untuk mengetahui pengaruh fitur individual dan kombinasi fitur terhadap performa model *Convolutional Neural Network* (CNN) dalam melakukan lokalisasi *Premature Ventricular Contraction* (PVC). Fitur yang digunakan dalam penelitian ini terdiri dari tiga domain utama, yaitu domain spektral, domain waktu-frekuensi, dan domain non-linear. Ketiga domain tersebut digunakan karena masing-masing memiliki kemampuan yang berbeda dalam merepresentasikan karakteristik sinyal ECG.

Daftar fitur ciri yang akan dievaluasi dalam penelitian ini ditunjukkan pada Tabel 3.7.

Tabel 3.7: *Fitur Ciri Evaluasi*

No	Metode Ekstraksi Fitur	Representasi Data
1	Power Spectrum Density (PSD)	Distribusi Daya Spektral
2	Wavelet Transform (CWT/DWT)	Representasi Waktu-Frekuensi
3	Higher-Order Statistics (HOS)	Korelasi Fase Non-Linear

Berdasarkan Tabel 3.7, penelitian ini tidak hanya melakukan pengujian terhadap fitur secara individual, tetapi juga menguji kombinasi antar fitur untuk mengetahui pengaruh fusi fitur terhadap performa lokalisasi PVC. Seluruh skenario pengujian dilakukan menggunakan skema pembagian data yang sama, yaitu *hold-out* 80% data training dan 20% data testing. Pada data training dilakukan validasi menggunakan metode *5-Fold Cross Validation*, sedangkan data testing digunakan sebagai data akhir untuk mengukur kemampuan generalisasi model terhadap data yang belum pernah dilihat sebelumnya.

Skenario pengujian yang digunakan dalam penelitian ini adalah sebagai berikut:

(a) **Skenario 0: Model Baseline**

Pada skenario ini, pengujian dilakukan menggunakan model CNN sederhana dengan parameter awal atau parameter default. Model baseline tidak menggunakan *feature fusion*, *hyperparameter tuning*, teknik balancing data, maupun Explainable Artificial Intelligence (XAI). Skenario ini digunakan sebagai acuan awal untuk mengetahui performa dasar CNN sebelum dilakukan pengembangan model lebih lanjut. Hasil dari model baseline akan menjadi pembanding utama terhadap seluruh skenario fitur individual dan kombinasi fitur.

(b) **Skenario 1: CNN dengan Fitur PSD**

Pada skenario ini, model CNN diuji menggunakan fitur Power Spectrum Density (PSD) sebagai input tunggal. Fitur PSD digunakan untuk merepresentasikan distribusi daya sinyal ECG pada domain frekuensi. Pengujian ini bertujuan untuk mengetahui sejauh mana informasi spektral mampu membantu model dalam membedakan lokasi PVC.

(c) **Skenario 2: CNN dengan Fitur Wavelet**

Pada skenario ini, model CNN diuji menggunakan fitur Wavelet sebagai input tunggal. Wavelet digunakan karena mampu merepresentasikan perubahan frekuensi sinyal ECG terhadap waktu. Pengujian ini bertujuan untuk mengetahui kemampuan fitur waktu-frekuensi dalam menangkap pola morfologi sinyal ECG, khususnya pada kompleks QRS yang berhubungan dengan PVC.

(d) **Skenario 3: CNN dengan Fitur HOS**

Pada skenario ini, model CNN diuji menggunakan fitur Higher-Order Statistics (HOS) sebagai input tunggal. Fitur HOS digunakan untuk menangkap karakteristik non-linear dan hubungan fase antar komponen frekuensi pada sinyal ECG. Pengujian ini bertujuan untuk mengetahui efektivitas informasi non-linear dalam mendukung proses lokalisasi PVC.

(e) **Skenario 4: CNN dengan Fusi Fitur PSD dan Wavelet**

Pada skenario ini, fitur PSD dan Wavelet digabungkan sebagai input model CNN. Kombinasi ini digunakan untuk menggabungkan informasi spektral dari PSD dan informasi waktu-frekuensi dari Wavelet. Pengujian ini bertujuan untuk mengetahui apakah kombinasi kedua fitur tersebut mampu meningkatkan performa dibandingkan penggunaan fitur tunggal.

(f) **Skenario 5: CNN dengan Fusi Fitur PSD dan HOS**

Pada skenario ini, fitur PSD dan HOS digabungkan sebagai input model CNN. PSD merepresentasikan distribusi daya pada domain frekuensi, sedangkan HOS merepresentasikan karakteristik non-linear dan hubungan fase sinyal. Pengujian ini bertujuan untuk mengetahui pengaruh kombinasi informasi spektral dan non-linear terhadap performa lokalisasi PVC.

(g) **Skenario 6: CNN dengan Fusi Fitur Wavelet dan HOS**

Pada skenario ini, fitur Wavelet dan HOS digabungkan sebagai input model CNN. Wavelet digunakan untuk menangkap informasi waktu-frekuensi, sedangkan HOS digunakan untuk menangkap hubungan non-linear pada sinyal. Pengujian ini bertujuan untuk mengetahui apakah kombinasi informasi waktu-frekuensi dan non-linear dapat memberikan representasi yang lebih kuat terhadap karakteristik PVC.

(h) **Skenario 7: CNN dengan Fusi Fitur PSD, Wavelet, dan HOS**

Pada skenario ini, ketiga fitur utama, yaitu PSD, Wavelet, dan HOS, digabungkan menggunakan skema *feature fusion*. Fusi fitur dilakukan untuk menggabungkan informasi spektral, waktu-frekuensi, dan non-linear ke dalam satu model CNN. Pengujian ini bertujuan untuk memvalidasi apakah integrasi ketiga fitur mampu menghasilkan performa terbaik dibandingkan fitur individual maupun kombinasi dua fitur.

Setiap skenario dievaluasi menggunakan metrik yang sama, yaitu akurasi, presisi, recall, F1-score, dan AUC. Selain itu, waktu komputasi dan penggunaan memori juga dianalisis untuk mengetahui efisiensi masing-masing skenario.

Dengan menggunakan skenario pengujian tersebut, penelitian ini dapat membandingkan performa model secara lebih objektif, baik pada fitur tunggal, kombinasi dua fitur, maupun kombinasi seluruh fitur.

3.1.15 Perbandingan Hasil Penelitian

Tugas Akhir ini melakukan perbandingan hasil yang didapat dengan dua pendekatan utama, yaitu perbandingan terhadap model baseline yang dibangun dalam penelitian ini dan perbandingan terhadap penelitian sejenis yang telah dilakukan sebelumnya. Perbandingan terhadap baseline dilakukan untuk mengetahui sejauh mana penggunaan fitur PSD, Wavelet, HOS, serta skema fusi fitur mampu memberikan peningkatan performa dibandingkan model CNN sederhana.

Selain itu, hasil penelitian juga dibandingkan dengan penelitian terdahulu yang secara spesifik membahas lokalisasi dan deteksi *Premature Ventricular Contraction* (PVC) menggunakan pendekatan *state-of-the-art*. Perbandingan ini dilakukan untuk mengetahui posisi dan kontribusi penelitian yang diusulkan terhadap perkembangan metode lokalisasi PVC. Ringkasan perbandingan hasil penelitian tersebut disajikan pada Tabel 3.8.

Tabel 3.8: *Perbandingan Hasil Penelitian Terkait PVC*

No	Penulis	Hasil Riset Utama
1	Sánchez et al. (2025)	Penurunan rata-rata kesalahan lokalisasi dari 30,69 mm menjadi 7,81 mm.
2	Baek et al. (2026)	Nilai <i>macro-average</i> AUC sebesar 0,915 untuk klasifikasi empat lokasi anatomi utama.
3	Gao et al. (2025)	Akurasi deteksi mencapai 99,55% menggunakan 11 fitur morfologi QRS.

Berikut adalah penjelasan mendalam mengenai perbandingan dengan penelitian-penelitian terbaru tersebut:

(a) **Penelitian oleh Jorge Sánchez dan rekan-rekan (2025)**

Menurut temuan yang dipublikasikan oleh Jorge Sánchez et al. [2], lokalisasi PVC dapat dioptimalkan secara signifikan melalui penggabungan citra elektrokardiografi dengan teknologi *cardiac digital twins* (ECGI-DT). Penelitian ini membuktikan bahwa penggunaan simulasi jantung personal untuk menciptakan basis data PVC sintetis yang luas dapat menurunkan rata-rata kesalahan lokalisasi dari 30,69 mm menjadi hanya 7,81 mm. Hal ini memberikan bukti kuat bahwa pemodelan fisik yang presisi memiliki potensi besar dalam perencanaan prosedur ablasi klinis, meskipun strategi ini membutuhkan daya komputasi yang jauh lebih be-

sar dibandingkan dengan pendekatan fusi fitur HOS, PSD, dan Wavelet yang diusulkan dalam tugas akhir ini.

(b) **Penelitian oleh Y. Baek dan tim (2026)**

Dari analisis yang dilakukan oleh Y. Baek et al. [4], diperkenalkan sebuah model berbasis kecerdasan buatan (*Transformer*) yang dirancang khusus untuk melokalisasi asal PVC ke dalam empat kategori anatomis utama, yaitu LVOT, RVOT, LV Non-OT, dan RV Non-OT. Dengan memanfaatkan mekanisme *self-attention*, model ini mampu menangkap korelasi temporal yang dalam dari sinyal ECG 12-lead secara simultan dan menghasilkan performa yang stabil dengan nilai *macro-average* AUC sebesar 0,915. Penekanan pada arsitektur yang mampu menangkap hubungan spasial-temporal ini menjadi poin perbandingan yang penting terhadap efektivitas arsitektur CNN multi-cabang yang digunakan dalam penelitian ini.


(c) **Penelitian oleh Qin Gao dan kawan-kawan (2025)**

Menurut laporan riset dari (author?) [1], deteksi PVC dilakukan menggunakan algoritma *Random Forest* yang didasarkan pada ekstraksi 11 parameter fitur morfologi QRS yang sangat terinterpretasi secara klinis. Fitur-fitur yang diekstraksi meliputi tingginya puncak gelombang, lebar durasi, serta parameter kompleks yang mencerminkan energi total depolarisasi ventrikel. Penelitian ini berhasil mencapai tingkat akurasi sebesar 99,55% pada dataset standar MIT-BIH. Perbandingan ini menunjukkan bahwa fitur morfologi tradisional yang dikombinasikan dengan *ensemble learning* tetap memiliki relevansi tinggi, namun penelitian tugas akhir ini mencoba memberikan kontribusi lebih melalui penggunaan fitur non-linear (HOS) untuk meningkatkan presisi lokalisasi spasial.

Penghitungan dan perbandingan ini dilakukan untuk memastikan bahwa hasil yang diperoleh dari integrasi fitur HOS, Wavelet, dan PSD dalam model CNN memiliki posisi tawar yang kuat serta mampu menjawab tantangan dalam lokalisasi titik asal PVC secara non-invasif.

3.2 Desain Sistem

Gambar 3.7 menunjukkan desain sistem yang digunakan dalam penelitian ini untuk melakukan lokalisasi *Premature Ventricular Contraction* (PVC) menggunakan model *Convolutional Neural Network* (CNN) dengan pendekatan ekstraksi fitur *Power Spectrum Density* (PSD), *Wavelet Transform*, dan *Higher-Order Statistics* (HOS).



Gambar 3.7: Desain Sistem Lokalisasi PVC menggunakan CNN

Seperti terlihat pada Gambar 3.7, sistem dimulai dari tahap **input data** berupa sinyal ECG 12-lead yang berasal dari dataset publik. Data sinyal tersebut kemudian masuk ke tahap **preprocessing** untuk meningkatkan kualitas sinyal melalui proses reduksi *noise*, normalisasi data, serta segmentasi sinyal ECG sehingga data menjadi lebih seragam dan siap digunakan pada tahap analisis berikutnya.

Setelah preprocessing selesai dilakukan, sistem melakukan **ekstraksi fitur** menggunakan tiga pendekatan yang berbeda. Metode pertama adalah *Power Spectrum Density* (PSD) yang digunakan untuk memperoleh distribusi energi sinyal pada domain frekuensi. Metode kedua adalah *Wavelet Transform* yang digunakan untuk menghasilkan representasi waktu-frekuensi dari sinyal ECG sehingga perubahan pola sinyal dapat diamati secara lebih detail. Metode ketiga adalah *Higher-Order Statistics* (HOS) yang digunakan untuk menangkap karakteristik non-linear dan korelasi fase yang tidak dapat direpresentasikan oleh statistik orde rendah.

Hasil ekstraksi fitur dari ketiga metode tersebut selanjutnya digunakan sebagai masukan bagi model *Convolutional Neural Network* (CNN). Pada tahap ini dilakukan proses pembelajaran pola menggunakan pendekatan *Multi-Branch CNN*, di mana setiap cabang model memproses representasi fitur yang berbeda sebelum dilakukan proses fusi fitur untuk menghasilkan keputusan klasifikasi.

Tahap akhir sistem adalah **evaluasi model**. Hasil prediksi lokasi PVC kemudian dievaluasi menggunakan beberapa metrik performansi, yaitu *accuracy*, *specificity*, *sensitivity*, *precision*, *F1-score*, dan *Area Under Curve* (AUC). Evaluasi dilakukan untuk membandingkan efektivitas masing-masing metode ekstraksi fitur serta menentukan konfigurasi fitur terbaik dalam mendukung proses lokalisasi PVC.

3.3 Ringkasan

Bab ini telah menjelaskan metodologi penelitian serta desain sistem yang digunakan dalam penelitian mengenai analisis dan perbandingan efektivitas fitur *Higher-Order Statistics* (HOS), *Wavelet Transform*, dan *Power Spectrum Density* (PSD) dalam model *Convolutional Neural Network* (CNN) untuk lokalisasi *Premature Ventricular Contraction* (PVC).

Metode penelitian yang diterapkan menggunakan pendekatan eksperimen komparatif dengan membandingkan beberapa skenario penggunaan fitur, baik fitur tunggal maupun kombinasi fitur, menggunakan prosedur pelatihan dan evaluasi yang sama. Penelitian dimulai dari tahapan studi literatur, pengumpulan data ECG 12-lead dari dataset publik, preprocessing sinyal, ekstraksi fitur, perancangan model CNN, pengujian model, hingga analisis hasil pengujian.

Pada bagian framework penelitian telah dijelaskan alur penelitian secara sistematis mulai dari tahap awal hingga diperoleh kesimpulan penelitian. Selanjutnya, bagian desain sistem menggambarkan arsitektur umum sistem klasifikasi PVC yang dibangun, dimulai dari input data ECG, preprocessing sinyal, proses ekstraksi fitur menggunakan PSD, Wavelet, dan HOS, kemudian dilanjutkan dengan proses klasifikasi menggunakan model CNN berbasis *feature fusion*. Tahap akhir dilakukan evaluasi performansi model menggunakan metrik *accuracy*, *specificity*, *sensitivity*, *precision*, *F1-score*, dan *Area Under Curve* (AUC).

Secara keseluruhan, metodologi dan desain sistem yang telah dirancang pada bab ini menjadi landasan implementasi penelitian untuk menganalisis kontribusi masing-masing metode ekstraksi fitur terhadap performa model CNN dalam mendukung proses lokalisasi PVC secara lebih akurat, objektif, dan terukur. Hasil rancangan pada bab ini selanjutnya akan digunakan sebagai acuan utama pada tahap implementasi, pelatihan model, serta analisis hasil penelitian pada bab berikutnya.

Daftar Pustaka

- [1] Q. Gao, F. Du, and W. Xu, “Random forest-based ecg premature ventricular contraction detection,” *Journal of Mechanics in Medicine and Biology*, vol. 25, no. 02, p. 2540012, 2025.
- [2] J. Sánchez, I. Llorente-Lipe, C. B. Espinosa, A. Loewe, I. Hernández-Romero, J. Vicente-Puig, S. Ros, F. Atienza, A. Carta-Bergaz, A. M. Clement, *et al.*, “Enhancing premature ventricular contraction localization through electrocardiographic imaging and cardiac digital twins,” *Computers in Biology and Medicine*, vol. 190, p. 109994, 2025.
- [3] A. S. Ba Mahel, S. Cao, K. Zhang, S. A. Chelloug, R. Alnashwan, and M. S. A. Muthanna, “Advanced integration of 2dcnn-gru model for accurate identification of shockable life-threatening cardiac arrhythmias: a deep learning approach,” *Frontiers in Physiology*, vol. 15, p. 1429161, 2024.
- [4] Y. Baek, C. Seo, S. Lee, Y. Kim, H. Lee, J. Jeong, Y. Kim, J. Shim, and J. Choi, “Artificial intelligence-guided localization of pvc origins from 12-lead ecg: development and clinical validation,” *European Heart Journal - Digital Health*, vol. 7, no. Supplement₁, p. ztaf143.133, 2026.
- [5] S. Zhou, A. A. Wahab, J. L. Sapp, E. Sung, K. N. Aronis, J. W. Warren, P. J. MacInnis, R. Shah, B. M. Horáček, R. Berger, *et al.*, “Assessment of an ecg-based system for localizing ventricular arrhythmias in patients with structural heart disease,” *Journal of the American Heart Association*, vol. 10, no. 19, p. e022217, 2021.
- [6] B. K. Pradhan, B. C. Neelappu, J. Sivaraman, D. Kim, and K. Pal, “A review on the applications of time-frequency methods in ecg analysis,” *Journal of Healthcare Engineering*, vol. 2023, p. 3145483, 2023.
- [7] A. K. Singh and S. Krishnan, “Ecg signal feature extraction trends in methods and applications,” *BioMedical Engineering OnLine*, vol. 22, no. 1, p. 22, 2023.
- [8] L. Zhao, P. Li, J. Li, and C. Liu, “Influence of ectopic beats on heart rate variability analysis,” *Entropy*, vol. 23, no. 6, p. 648, 2021.

- [9] A. J. Chashmi and M. C. Amirani, “An efficient and automatic ecg arrhythmia diagnosis system using dwf and hos features and entropy-based feature selection procedure,” *Journal of Electrical Bioimpedance*, vol. 10, no. 1, pp. 47–54, 2019.
- [10] P. Novotna, T. Vicar, M. Ronzhina, J. Hejc, and J. Kolarova, “Deep-learning premature contraction localization in 12-lead ecg from whole signal annotations,” vol. 47, pp. 1–4, 2020.
- [11] D. Han, J. Moon, L. R. M. Diaz, D. Chen, D. Williams, F. Mohagheghian, O. Ghetia, A. G. Peitzsch, Y. Kong, N. Nishita, *et al.*, “Multiclass arrhythmia classification using multimodal smartwatch photoplethysmography signals collected in real-life settings,” *Research Square*, 2024.
- [12] J. Svehlikova and M. Tysler, “Noninvasive localization of premature ventricular activity using different equivalent point sources,” in *Computing in Cardiology 2016*, vol. 43, pp. 239–242, IEEE, 2016.
- [13] A. Sayin and D. Akgun, “Pattern of bispectral index in abnormal ecg,” *Biomedical Signal Processing and Control*, vol. 44, pp. 1–10, 2018.
- [14] N. Prasad *et al.*, “Analysis of non-linear ecg signals using higher-order statistics,” *Journal of Medical Systems*, vol. 37, pp. 1–15, 2013.
- [15] M. Tysler *et al.*, “Non-invasive identification of pvc origin for catheter ablation planning,” *Measurement Science Review*, vol. 19, no. 6, pp. 246–252, 2019.
- [16] J. Zheng, “An novel ecg database to identify outflow tract origins of idiopathic ventricular arrhythmia,” 2019.

Lampiran A

Jadwal Kegiatan

Lampiran ini berisi jadwal kegiatan pelaksanaan proposal tugas akhir. Jadwal disusun sebagai acuan tahapan penelitian, mulai dari studi literatur, pengumpulan data, preprocessing, ekstraksi fitur, perancangan model CNN, pengujian model, hingga penyusunan laporan akhir. Rincian jadwal kegiatan ditunjukkan pada Tabel 3.9.

Tabel 3.9: Jadwal kegiatan proposal tugas akhir

No	Kegiatan	Bulan ke-											
		1			2			3			4		
1	Studi Literatur												
2	Pengumpulan Data ECG 12-lead												
3	Preprocessing Data ECG												
4	Ekstraksi Fitur PSD, Wavelet, dan HOS												
5	Perancangan Model CNN Baseline												
6	Hyperparameter Tuning dan Penanganan Ketidakseimbangan Data												
7	Pengujian Model dan Evaluasi Metrik												
8	Analisis Hasil dan Explainable Artificial Intelligence (XAI)												
9	Penulisan Laporan												
10	Finalisasi dan Revisi Laporan												